ТЕХНИЧЕСКИЙ ОТЧЁТ · МОДЕЛЬ V5

WetlandEar: как мы построили и обучили систему распознавания птиц для заповедников

Данные, архитектура, обучение, проверка качества, база и ограничения. Подробно, с кодом, графиками и объяснениями простым языком.

Проект	WetlandEar: приложение app.wetlandear.tech и сайт wetlandear.tech
Авторы	Жасмин Джуманова, команда проекта WetlandEar
Версия модели	v5 (268 видов, 7 822 записей); глава 13 описывает выложенную v6
Дата	11.10.2026
Репозитории	приложение (wetlandear-app), сайт (wetlandear), материалы по обучению (wetlandear-ml)

Для кого этот документ
Для читателя без подготовки по машинному обучению. Каждая глава начинается с цели, а в блоках «Простыми словами» сложное объяснено через повседневные примеры. Технический читатель найдёт настоящий код (он вырезан из файлов проекта, а не переписан), формулы и протокол проверки.
Все числа взяты из журналов обучения и файла метрик. Там, где данных мало или проверка слабая, об этом сказано прямо.

Содержание

Аннотация 4

Как читать этот документ 4

1. Введение и постановка задачи 5

1.1. Зачем это нужно 5

1.2. Что уже есть и чего не хватает 5

1.3. Вклад проекта 6

2. Система целиком 6

2.1. Путь одного звука 7

2.2. Технологии и почему такие 7

3. Данные 7

3.1. Источники 8

3.2. Как выбирали виды 8

3.3. Как запись превращается в обучающие примеры 9

3.4. Аудит данных: что мы нашли 10

3.5. Лицензии и ограничения использования 10

4. Модель: что именно мы построили и почему 10

4.1. Три слоя системы распознавания 10

4.2. Почему именно так: решения и альтернативы 11

4.3. Наш слой: логистическая регрессия 11

4.4. Смешивание с BirdNET и калибровка 12

4.5. Вспомогательные части: место и тип звука 12

5. Обучение шаг за шагом 12

5.1. Оборудование и время 13

5.2. Шаги и скрипты 13

5.3. Шумовые копии: зачем и как 14

5.4. Обучение слоя и честная проверка 14

5.5. Экспорт: что попадает в приложение 15

6. Как мы проверяли качество и что получили 15

6.1. Протокол 15

6.2. Главный результат 15

6.3. Шум 16

6.4. Можно ли верить процентам 17

6.5. По видам 18

7. История, ветви развития и репозитории 19

7.1. Как шло развитие модели 19

7.2. Что мы пробовали и отвергли 20

7.3. Репозитории и ветки Git 20
8. Тревоги: выстрелы и двигатели 20
9. Приложение, база и безопасность 21
9.1. Что умеет приложение (вокруг модели) 21
9.2. База данных 22
10. Честные ограничения 22
11. Что дальше 23
12. Как воспроизвести 23
13. Обновление: модель v6 выложена 24
13.1. Что изменилось 24
13.2. Один и тот же тест, два вида записей 24
13.3. Общие цифры v6 25
13.4. Сбой, который мы поймали 25
Приложение А. Глоссарий 26
Приложение Б. Источники и благодарности 27
Приложение В. Точность по каждому из 268 видов 27

Аннотация

Заповедникам нужно понимать, какие птицы живут на их территории, но слушать сотни часов записей вручную невозможно. Существует готовая нейросеть BirdNET, которая определяет около 6,5 тысяч видов по звуку, однако она плохо знает часть видов Казахстана: например, кудрявого пеликана в её списке нет совсем. Мы построили систему WetlandEar, где BirdNET служит «ушами», а поверх неё обучен небольшой собственный слой, настроенный на виды нашего региона и на шумные полевые условия.

Слой обучался на 7 822 записях 268 видов из открытых баз (Xeno-canto, iNaturalist) на обычном ноутбуке, без видеокарты. Проверка велась так, чтобы одна и та же запись никогда не попадала и в обучение, и в тест. На 3-секундных фрагментах чистых записей точность выросла с 61,1% (BirdNET без дообучения, ограниченный нашим списком видов и без фильтра места: самое честное сравнение) до 74,2%, а при голосовании по всем фрагментам одной записи составила 85,0%. Проект раньше публиковал другую базовую цифру BirdNET (56,3%); при подготовке отчёта выяснилось, что она занижена фильтром места, и в главе 6 это разобрано. Модель выдаёт проценты, которым можно доверять: при уверенности от 0,5 верными оказываются около 91% ответов.

В отчёте описано, откуда взяты данные, как устроена вся система (приложение, сервер, база), как шло обучение шаг за шагом, почему выбраны именно такие решения, что мы пробовали и отвергли, как проверяли качество, где модель слаба и что нужно сделать дальше. Главная оговорка: проверка выполнена на записях из открытых баз; на записях с реального болота она ещё впереди.

Ключевые цифры

- Видов в модели: **268**; записей в обучении: **7 822**; 3-секундных окон: **76 391** чистых и **82 264** шумных копий.
- Точность по окнам: BirdNET (честное сравнение) **61,1%** → WetlandEar **74,2%**, прирост около **13,1** п.п. По записи целиком: **85,0%**.
- На шумных окнах: BirdNET (на том же списке видов) **51,0%** → WetlandEar **67,5%**.
- Размер нашей модели: около **500 КБ**; работает на процессоре за миллисекунды, в том числе в браузере без интернета.

Как читать этот документ

Если вы никогда не работали с нейросетями, достаточно запомнить четыре слова. Остальные термины собраны в глоссарии в конце.

- **Окно** — кусочек звука длиной 3 секунды. Модель всегда смотрит на такой кусочек, как мы смотрим на один кадр видео.
- **Отпечаток** (по-научному эмбеддинг) — набор из 1024 чисел, в который BirdNET превращает окно. Похожие звуки получают похожие отпечатки, как похожие лица получают похожие описания.
- **Слой** (по-научному «голова», head) — наша маленькая модель, которая по отпечатку решает, какой это вид.
- **Проверка по записям** — способ измерить качество честно: запись, на которой проверяем, модель никогда не видела при обучении.

Простыми словами: как это работает целиком
Представьте опытного слушателя птиц (BirdNET). Он слышит звук и пересказывает его языком «ощущений» — это отпечаток. Но он родом из другой страны и не знает наших местных голосов по именам. Мы не переучиваем его с нуля. Мы нанимаем помощника, который сидит рядом и по этим «ощущениям» учится узнавать именно наши виды, тренируясь на тысячах размеченных записей. Решение принимается вместе: слушатель и помощник голосуют, а потом проценты «подгоняются», чтобы уверенность модели совпадала с реальной долей правильных ответов.

1. Введение и постановка задачи

1.1. Зачем это нужно

Акустический мониторинг — один из самых дешёвых способов следить за птицами: рекордер на станции круглосуточно пишет звук, а специалисты потом выбирают из записей нужное. Узкое место — разметка. Час записи слушать час, а рекордеров несколько и пишут они месяцами. Автоматическое распознавание снимает основную работу, но оно полезно только тогда, когда ему можно доверять и когда понятно, где оно ошибается.

Целевой пользователь — сотрудник заповедника (рейнджер, орнитолог, директор), а не специалист по данным. Поэтому требования к системе такие:

1. **Работать на недорогом оборудовании.** У заповедника нет GPU-серверов. Распознавание должно идти на процессоре, а лучше и в телефоне.
2. **Работать без интернета.** Болото и степь — это часто нет связи. Нужен режим, где модель живёт прямо в браузере.
3. **Знать виды региона.** Редкие и краснокнижные виды важнее обычных, а именно их глобальные модели знают хуже всего.
4. **Не обманывать.** Проценты уверенности должны быть честными, а окончательное решение принимает человек: модель только предлагает.
5. **Быть прозрачной.** Заповедник должен видеть, на чём модель училась, как проверялась и где слаба.

1.2. Что уже есть и чего не хватает

BirdNET V2.4 (Корнелльская лаборатория орнитологии и Технический университет Хемница) — открытая нейросеть, обученная на огромном числе записей. Она определяет 6 522 метки и годится как основа. Но у неё три слабых места для нашей задачи. Во-первых, часть видов Казахстана в её списке отсутствует. Во-вторых, для видов, которые есть, она часто ошибается на региональных вариантах голоса. В-третьих, её проценты не откалиброваны: «0,9» не означает, что она права в девяти случаях из десяти.

Простыми словами: почему нельзя просто взять BirdNET
Это как переводчик, который отлично знает 6 500 слов, но не знает местных диалектов. Для большинства слов он справится, а вот на редких и местных будет путаться или молчать. Мы не выбрасываем его знания, а добавляем рядом помощника, знающего диалект.

1.3. Вклад проекта

- Собран и очищен набор записей **268 видов** Казахстана из открытых баз с учётом лицензий.
- Обучен лёгкий слой поверх BirdNET и объединён с его собственными баллами; уверенность откалибрована.
- Оценка по записям, а не по фрагментам, с отдельной проверкой на шуме: камыш, ветер, вода, дождь, чужие птицы.
- Весь пайплайн воспроизводим на ноутбуке; модель весит около 500 КБ и работает на сервере и в браузере без интернета.
- Вокруг модели построена рабочая система: приложение, Telegram-бот, ИИ-ассистенты, публичные страницы, отчёты, команды.

2. Система целиком

Модель — только одна деталь. Чтобы ею могли пользоваться сотрудники, вокруг неё построено приложение и серверная часть. Схема ниже показывает, как звук доходит до отчёта.

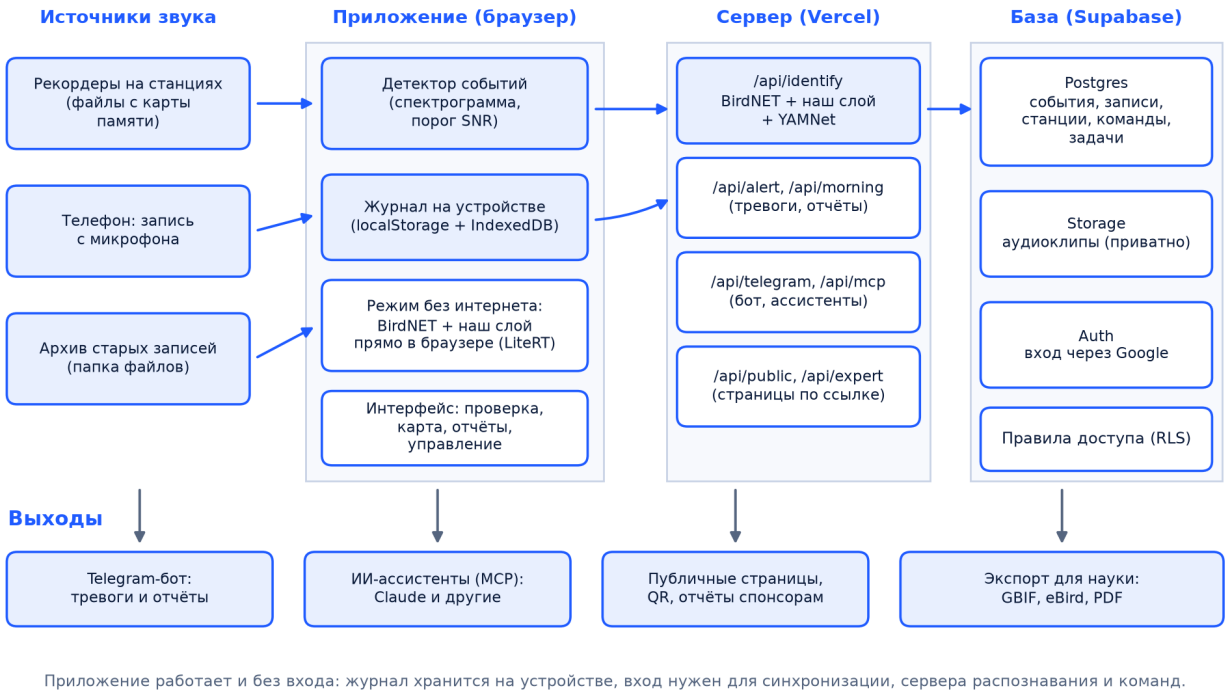


Рис. 1. Архитектура WetlandEar. Слева источники звука, затем приложение в браузере, серверные функции и база. Снизу то, что получает пользователь.

2.1. Путь одного звука

1. **Запись.** Звук приходит с рекордера (файлы) или с микрофона телефона. Приложение работает как веб-страница (PWA) и ставится на телефон.
2. **Поиск событий.** Прямо в браузере спектрограмма просматривается на предмет «выделяющихся» звуков (порог по отношению сигнал/шум). Тишина и шум без событий не идут дальше.
3. **Распознавание.** Для каждого события вырезаются 3-секундные окна и отправляются на сервер (`/api/identify`) либо обрабатываются локально в режиме без интернета. Там работают BirdNET, наш слой и YAMNet (определяет тип звука: выстрел, двигатель, голос, дождь).
4. **Предложения вместо ответов.** Приложение показывает несколько вариантов с процентами. Человек подтверждает, исправляет или отклоняет. Только подтверждённое считается наблюдением.
5. **Журнал и синхронизация.** События хранятся на устройстве; после входа через Google синхронизируются в базу и доступны команде.
6. **Результат.** Тревоги и отчёты в Telegram, экспорт для науки (GBIF, eBird), PDF, публичные страницы, ответы ИИ-ассистентов.

2.2. Технологии и почему такие

Часть	Что используем	Почему так
Приложение	Статическая веб-страница (PWA), чистый JavaScript, без сборки	Устанавливается на телефон, работает офлайн, не нужен магазин приложений; нет сложного окружения, которое надо поддерживать.
Серверные функции	Vercel, Python (`api/*.py`)	Платим только за вызовы; BirdNET работает на процессоре за секунды; код рядом с приложением.
База и вход	Supabase: Postgres, Storage, Auth (Google)	Правила доступа на уровне строк (RLS): человек видит только своё и данные своей команды, даже если ошибся код приложения.
Распознавание без сети	LiteRT (WASM) в браузере	Те же BirdNET и наш слой запускаются в телефоне; ответы совпадают с серверными.
Бот и ассистенты	Telegram, MCP-сервер	Тревоги и отчёты там, где люди уже сидят; ИИ-ассистенты читают журнал и проверяют события от имени человека.
Безопасность	Строгая политика CSP (без встроенных скриптов), HSTS, ключи только на сервере	Меньше риска, что чужой скрипт украдёт данные; секретные ключи не попадают в браузер.

3. Данные

Качество модели определяется данными сильнее, чем алгоритмом. Здесь описано, откуда взяты записи, как мы их отбирали и проверяли, и какие проблемы нашли.

3.1. Источники

Источник	Что берём	Условия
Xeno-canto (API v3)	Основа: 7 795 файлов записей птиц с подписью вида	Нужен бесплатный ключ. Записи с лицензией «без производных» (ND) исключены. Фильтр качества и лимит на страну, чтобы не получить только одну местность.
iNaturalist	Добавка для v6: 2 042 файлов, 205 видов	Только лицензии CC0, CC BY и CC BY-SA. Записи «не для коммерции» (CC BY-NC) намеренно пропущены.
Wikimedia Commons	Только для проверки тревог (выстрелы, двигатели, гроза, дождь, ветер)	Открытые лицензии, файлы до 6 МБ.
Ручной этап	33 файла из самой первой выборки	Аудит показал, что 9 из них подписаны не тем видом (см. 3.4). Они убраны в карантин.

Простыми словами: откуда у модели «учебник»
Это как учить ребёнка узнавать птиц по аудиокнигам: берём тысячи записей, где человек уже сказал, какая птица поёт. Xeno-canto — огромная общая «библиотека» таких записей, которую пополняют любители и учёные по всему миру. iNaturalist — похожая база наблюдений. Мы берём только то, что авторы разрешили использовать.

3.2. Как выбирали виды

Основа — список видов Кургальджинских озёр, который используется в приложении по умолчанию (18 видов: фламинго, пеликаны, журавли, лебеди, гуси, огарь, хохотун и др.). Затем набор расширялся списком птиц Казахстана и приоритетом для редких и краснокнижных видов. В v5 его размер — 268 видов; для самых редких брали *всё* пригодное на Xeno-canto, для остальных около 24–32 записей.

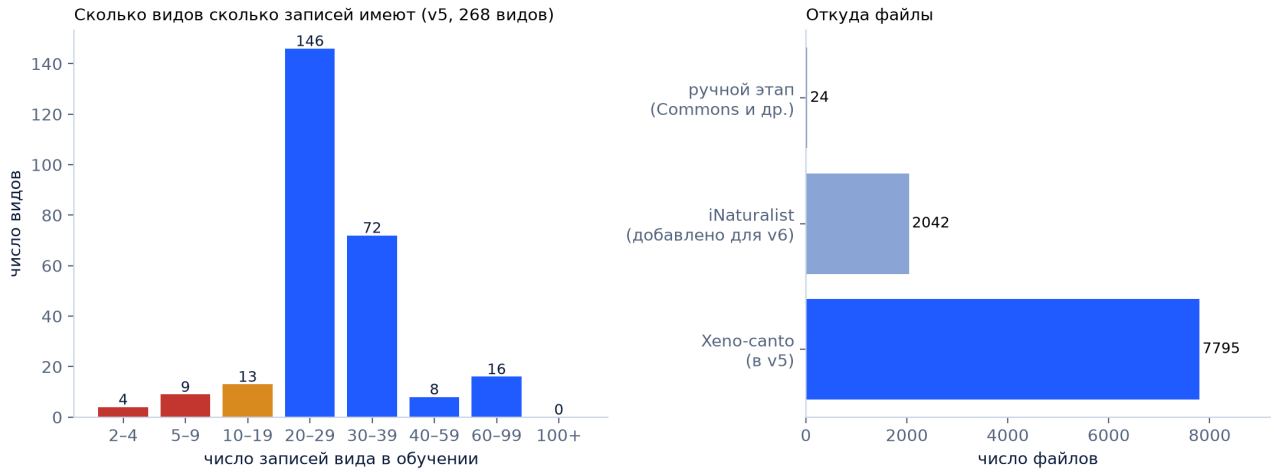


Рис. 2. Слева: сколько видов сколько записей имеют в обучении (красное — критически мало). Справа: откуда взяты файлы. Данные iNaturalist добавлены к v6 и в v5 не участвовали.

Распределение неравномерное, и это главная причина слабых мест. Видов, у которых записей меньше 10: **13**; меньше 15: **17**. Именно такие виды (кудрявый пеликан — 2 записи, джек (дрофа-красотка) — 3, балобан — 3) дают самую низкую точность. Никакой алгоритм не заменит отсутствующие примеры.

3.3. Как запись превращается в обучающие примеры

Запись режется на окна по 3 секунды с шагом 1,5 секунды. Из них берутся **14 самых громких** (там, скорее всего, поёт птица) и **3 самых тихих** (это «фон» — модель должна уметь сказать «птицы нет»). Для каждого окна считается отпечаток BirdNET. После этого сам звук обучению не нужен, остаются только отпечатки: это быстро и экономит место.

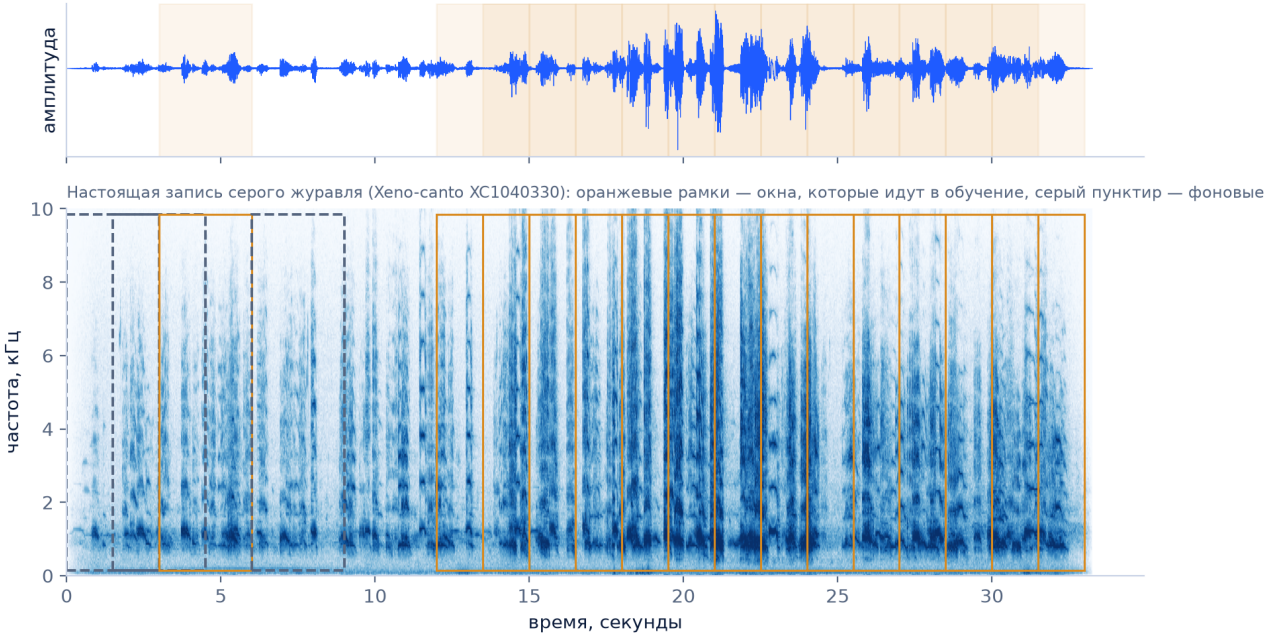


Рис. 3. Настоящая запись из обучающего набора. Сверху форма сигнала, снизу спектрограмма (яркость — громкость на каждой частоте). Оранжевые рамки — окна, идущие в обучение; серые пунктирные — фоновые.

```
32  def one_file(path):
33      import soundfile as sf
34      from scipy.signal import resample_poly
35      I, s, y, lab, plaus = _ctx['I'], _ctx['s'], _ctx['y'], _ctx['lab'], _ctx['plaus']
36      x, sr = sf.read(path, dtype='float32'); x = x.mean(1) if x.ndim > 1 else x
37      x = resample_poly(x, 48000, sr).astype('float32')
38      n = 144000
39      if len(x) < n: x = np.pad(x, (0, n - len(x)))
40      ws = [x[i:i + n] for i in range(0, len(x) - n + 1, n // 2)]
41      en = np.array([float((w ** 2).mean()) for w in ws]); order = np.argsort(en)[::-1]
42      strong = list(order[:min(14, len(ws))]); weak = list(order[-3:]) if len(ws) > 8 else []
43      clf = s['clf']; oidx = clf.get_output_details()[0]['index']
44      out = []
45      for idx, bg in [(i, 0) for i in strong] + [(i, 1) for i in weak]:
46          w = ws[idx]
47          L = I._run(clf, w.reshape(1, -1)).copy(); eb = clf.get_tensor(oidx - 1)[0].copy()
48          P = 1 / (1 + np.exp(-np.clip(L, -15, 15))); P = np.where(plaus, P, 0); k = int(np.argmax(P))
49          x16 = w.reshape(-1, 3).mean(axis=1)
50          ey = np.mean([yam(y, x16[c - 7800:c + 7800]) for c in (9600, 24000, 38400)], axis=0)
51          out.append((eb / np.linalg.norm(eb), ey / (np.linalg.norm(ey) + 1e-9), lab[k], float(P[k]), bg))
52      return out
```

Файл `build_feats2.py`*, строки 32–52. Нарезка записи на окна и получение отпечатка. Звук приводится к 48 кГц, окна идут с шагом в половину длины, выбираются сильные и слабые.*

3.4. Аудит данных: что мы нашли

Перед финальным обучением мы проверили, нет ли в данных очевидных ошибок. Файлы Xeno-canto и iNaturalist называются по номеру записи, поэтому видовую подпись в них проверить по имени нельзя. А вот 33 файла ручного этапа названы с латинским видом. Скрипт `audit_labels.py` сверил название файла с папкой.

Папка (вид, под которым учили)	Что на самом деле в файле
Cygnus cygnus (лебедь-кликун)	Cygnus olor (шипун); Cygnus buccinator (лебедь-трубач, 2 файла); Cygnus atratus (чёрный лебедь)
Anser anser (серый гусь)	Anser albifrons (белолобый гусь); Anser serrirostris (гуменник)
Grus grus (серый журавль)	Grus canadensis (канадский журавль, 2 файла)
Tadorna tadorna (пеганка)	Tadorna ferruginea (огарь)

Итог: **9 файлов из 9 870** (0,09%) были подписаны не тем видом, причём все — близкими родственниками, самый коварный случай. Влияние на точность малое, но это ошибка в метках, и она исправлена: файлы перенесены в папку карантина (не удалены), признаки пересчитаны. Это вывод для будущих версий: подписи, взятые из имени файла, нужно сверять автоматически, а подписи самих баз (сделанные людьми-любителями) могут содержать ошибки, и мы пока не можем их оценить.

3.5. Лицензии и ограничения использования

BirdNET распространяется под лицензией CC BY-NC-SA, а многие записи Xeno-canto — под CC BY-NC-SA. Это значит, что модель и данные годятся для некоммерческих исследований и образования. Для платных услуг заповедникам нужно отдельно проверить юридическую чистоту (по-хорошему, получить письменное согласие правообладателей или заменить источники). Мы не делаем вид, что этой проблемы нет.

4. Модель: что именно мы построили и почему

4.1. Три слоя системы распознавания

Слой	Что делает	Чем реализован
1. Уши: BirdNET V2.4	Превращает 3 секунды звука в отпечаток (1024 числа) и в баллы по 6 522 меткам	Готовая нейросеть, не дообучается; мы лишь «вытащили» второй выход с отпечатком
2. Наш слой	По отпечатку решает, какой из 268 видов (или «фон»)	Логистическая регрессия, обучена нами
3. Смешивание и калибровка	Объединяет мнение слоя и баллы BirdNET; превращает числа в честные проценты	Формула в 4.4, температура подбирается по проверке
Вспомогательно: места и тип звука	Отсекает виды, невозможные в этой точке; различает птицу, выстрел, двигатель, дождь	Мета-модель BirdNET (по координатам) и YAMNet

4.2. Почему именно так: решения и альтернативы

Решение	Альтернатива	Почему выбрали это
Взять готовые «уши» (BirdNET)	Обучить нейросеть с нуля	Для нейросети с нуля нужны сотни тысяч размеченных записей и видеокарты. У нас около 7 822 записей и ноутбук.
Обучать только маленький слой	Дообучать всю нейросеть	Дообучение всей сети на малых данных быстро «запоминает» записи вместо птиц (переобучение), требует GPU и сложнее переносится в браузер.
Линейный слой (логистическая регрессия)	Небольшая нейросеть (MLP)	В тесте v2 MLP дала 56,5% против 72,5% у линейного слоя, а училась в 4,5 раза дольше (375 с против 84 с). На нашем объёме данных простое работает лучше.
Только отпечатки BirdNET	Добавить отпечатки YAMNet	Результат одинаков (72,4% против 72,5%), а система усложняется. Лишнее убрали.
Смешать слой с баллами BirdNET	Слой без BirdNET	Для видов, которые BirdNET знает, его собственный балл добавляет информацию. Вес 0,15 дал лучшую точность по окнам.
Класс «фон»	Всегда выбирать вид	Иначе модель «видит» птицу в любой тишине. Фон обучается из самых тихих окон записей.
Шумовые копии в обучении	Только чистые записи	Болото шумное. Обучение с шумом подняло точность на шумных окнах с 64,4% до 68,1% (v4) ценой 0,4 п.п. на чистых.
Проверка по записям	Случайное разбиение окон	Окна одной записи очень похожи; при случайном разбиении тест «подглядывает» в обучение и точность завышена.
Температура для процентов	Оставить «сырые» проценты	Сырые проценты обычно самоуверенны. Подбор температуры по отложенным данным делает «0,8» близким к «в 80% случаев прав».
Решение принимает человек	Полная автоматика	Цена ошибки в редком виде высока. Модель только предлагает; автозаполнение — лишь при уверенности 0,5 и выше.

4.3. Наш слой: логистическая регрессия

Вход слоя — отпечаток BirdNET длиной 1024, нормированный так, чтобы его длина была равна единице (L2-нормировка). Для каждого класса слой хранит свои 1024 коэффициента и смещение. Балл класса k — это скалярное произведение:

$$z_k = w_k \cdot x + b_k,\ p_k = \exp(z_k) / \Sigma_j \exp(z_j)$$

Параметры обучения: регуляризация `C = 2,0` (не даёт слою подгоняться под шум), `class_weight=balanced` (редкие виды весят больше, иначе слой почти всегда выбирал бы частые), 500 итераций в проверке и 800 в финальном обучении. Классов 269: виды плюс «фон». Для обучения берутся только виды минимум с двумя разными записями (иначе нечем проверять).

> **Простыми словами: что такое «слой» и «коэффициенты»**
> Отпечаток — это 1024 оценки: «насколько звук похож на то, насколько на это...». Для каждого вида слой запоминает, какие из этих оценок важны именно для него и с каким весом. Чтобы ответить, он просто складывает взвешенные оценки для каждого вида и выбирает того, у кого сумма больше. Это очень простая арифметика, поэтому она быстрая и помещается в 500 КБ.

4.4. Смешивание с BirdNET и калибровка

Итоговая уверенность считается так. К логарифму вероятности нашего слоя добавляется балл самого BirdNET для того же вида, умноженный на вес *w*. Затем всё делится на температуру *T* и нормируется:

$$f_k = (\log p_k + w \cdot \text{logit_BirdNET}(k)) / T, \text{ итог} = \text{softmax}(f)$$

Вес $w = 0{,}15$: достаточно, чтобы BirdNET «поправил» слой там, где хорошо знает вид, но недостаточно, чтобы он перетянул одеяло на себя. Для 19 видов, которых в BirdNET нет совсем (в том числе кудрявый пеликан), его вклад равен нулю, и решает только наш слой. Температура $T = 1{,}00$ подбиралась по ответам на отложенных записях; её значение около 1 означает, что проценты уже близки к честным. Пробовали и свой вес для каждого вида, но на записях, не участвовавших в подборе, это не помогло (71,2% → 70,9%), и мы оставили один общий вес.

```
111  def head_top(vec, logits):
112      h = _head()
113      if h is None:
114          return []
115      v = vec / (np.linalg.norm(vec) + 1e-9)
116      z = h['coef'] @ v + h['b']
117      logp = z - (z.max() + np.log(np.exp(z - z.max()).sum()))
118      bn = np.zeros(len(logp), dtype='float32')
119      ok = h['bn_idx'] >= 0
120      bn[ok] = np.clip(logits[h['bn_idx'][ok]], -15, 15)       # BirdNET's own opinion on the same species
121      f = (logp + h['w'] * bn) / h['T']
122      p = np.exp(f - f.max()); p /= p.sum()
123      out = []
124      for k in np.argsort(-p)[:4]:
125          if h['classes'][k] == 'background' or p[k] < .15:
126              continue
127          out.append({'sci': h['classes'][k], 'common': h['common'][k], 'conf': round(float(p[k]), 3)})
128      return out
```

Файл `identify.py`*, строки 111–128. Так формула из 4.4 записана в боевом коде сервера. Тот же расчёт повторён в браузерной версии, а паритет проверяется скриптом export_parity.py.*

4.5. Вспомогательные части: место и тип звука

- **Мета-модель BirdNET** по координатам станции оценивает, какие виды вообще встречаются в этом месте. Всё, что правдоподобно меньше чем на 3%, отсекается из подсказок. Сезонности она практически не учитывает: честная проверка (скрипт `test_meta_week.py`) показала, что неделя года почти не влияет на её ответ. Поэтому в приложении отдельно показывается подсказка «необычно для сезона» по данным Xeno-canto.
- **YAMNet** (Google, обучена на AudioSet) определяет тип звука: птица, выстрел, двигатель, голос, дождь. Она используется для тревог и для фильтра «это не птица»; о качестве тревог — в главе 8.

5. Обучение шаг за шагом

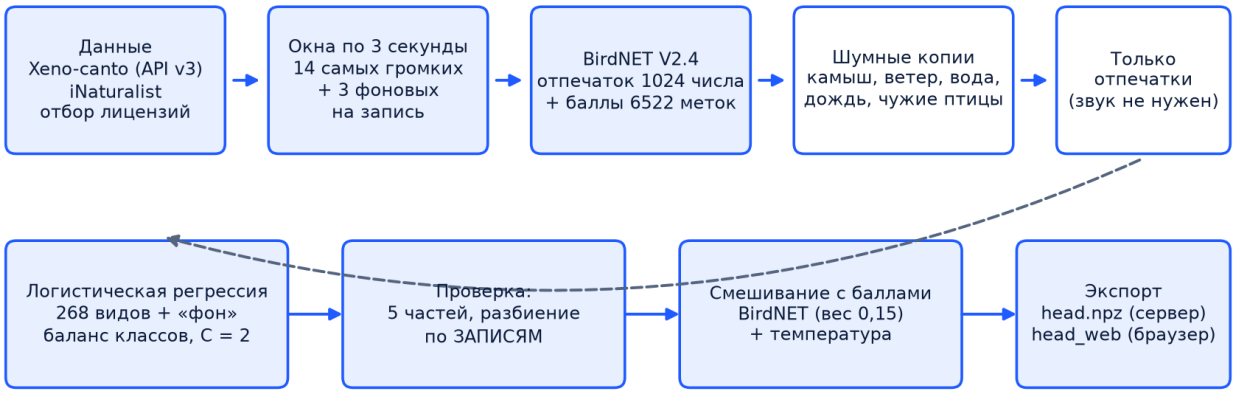


Рис. 4. Весь процесс от записей до готовой модели. Тяжёлая часть — подготовка отпечатков (BirdNET прогоняется по всем записям). Обучение самого слоя занимает минуты.

5.1. Оборудование и время

Всё делалось на ноутбуке с процессором Intel Core i7-12700H, 16 ГБ памяти, без использования видеокарты (в ноутбуке есть NVIDIA RTX 3050 Ti, но наша часть работы её не требует). BirdNET запускается на процессоре через библиотеку LiteRT. Подготовка признаков идёт параллельно по папкам видов, результат кэшируется по виду: если в папку добавили записи, пересчитывается только она. Именно благодаря кэшу мы можем добавлять новые данные за часы, а не за сутки.

5.2. Шаги и скрипты

№	Что происходит	Скрипт
1	Загрузка записей из Xeno-canto (с ключом, без файлов ND, с лимитами)	`fetch_xc4…7.py`
2	Докачка открытых записей iNaturalist для видов, где записей мало	`fetch_inat.py`
3	Аудит подписей в данных	`audit_labels.py`
4	Нарезка на окна и отпечатки BirdNET (с кэшем по видам)	`build_feats2.py`
5	Баллы BirdNET для наших видов на тех же окнах (для смешивания)	`build_logits.py`
6	Шумовые копии самых сильных окон	`build_noisy.py`
7	Обучение, проверка по записям, подбор температуры, метрики, экспорт	`train_v5.py --export`
8	Таблицы названий видов для приложения	`make_species_js.py`
9	Версия для браузера и проверка совпадения с серверной	`make_head_web.py`, `export_parity.py`

5.3. Шумовые копии: зачем и как

Записи Xeno-canto часто чистые. На настоящем болоте шумят камыш, ветер, вода, дождь, поют сразу несколько птиц. Если обучать только на чистых записях, модель теряется в шуме. Поэтому для самых сильных окон каждой записи мы делаем две «испорченные» копии: подмешиваем один из шести типов шума на случайной громкости (от −3 до +12 дБ относительно сигнала). Шум — частично синтетический (камыш, ветер, вода, дождь делаются фильтрацией случайного шума), частично настоящий (тихий фон из других записей и чужие птицы).

```
58  def synth(kind, rng):
59      from scipy.signal import butter, sosfilt
60      w = rng.standard_normal(N)
61      if kind == 'reeds':        # dry leaves/reed rustle: band-limited noise with crackle and slow gusts
62          y = sosfilt(butter(4, [1800, 11000], 'band', fs=SR, output='sos'), w) * gust(rng, 1.5)
63          imp = (rng.random(N) < 0.0015) * rng.standard_normal(N) * 6
64          y = y + sosfilt(butter(2, [2500, 9000], 'band', fs=SR, output='sos'), imp)
65      elif kind == 'wind':       # low rumble with gusts, a little hiss
66          y = sosfilt(butter(4, 450, 'low', fs=SR, output='sos'), w) * gust(rng, 0.6, 0.9) + 0.05 *
    ↳ sosfilt(butter(2, 3000, 'low', fs=SR, output='sos'), rng.standard_normal(N))
67      elif kind == 'water':      # pink-ish broadband, ripples
68          f = np.fft.rfft(w); fr = np.arange(len(f)) + 1.0; y = np.fft.irfft(f / np.sqrt(fr), N) *
    ↳ gust(rng, 20, 0.4)
69      else:                      # rain: bright noise with drops
70          y = sosfilt(butter(3, [900, 14000], 'band', fs=SR, output='sos'), w) * (0.6 + 0.4 * gust(rng, 8,
    ↳ 0.7))
71          y = y + sosfilt(butter(2, [3000, 12000], 'band', fs=SR, output='sos'), (rng.random(N) < 0.004) *
    ↳ rng.standard_normal(N) * 8)
72      return rms1(y.astype('float32'))
```

Файл `build_noisy.py`*, строки 58–72. Синтез шума «камыш» и «ветер». Полоса частот, порывы и «хруст» подобраны так, чтобы быть похожими на настоящие звуки.*

5.4. Обучение слоя и честная проверка

Записи разбиваются на 5 частей (`GroupKFold`) **по записям**: окна одной записи всегда попадают в одну часть. Слой по очереди обучается на четырёх частях и проверяется на пятой. Мы обучали два варианта и сравнивали их на чистых и на шумных окнах: слой на чистых данных и слой на чистых плюс шумных. Шумные копии тестовых записей в обучение не попадают.

```
61  def fit_pred(tr, te, train_noisy):
62      t = tr if train_noisy else tr[~isn[tr]]
63      mdl = LogisticRegression(C=CREG, max_iter=500, class_weight='balanced').fit(XA[t], YA[t])
64      P = np.zeros((len(te), len(classes)), dtype='float32'); P[:, np.searchsorted(classes, mdl.classes_)]
    ↳ = mdl.predict_proba(XA[te])
65      return P
```

Файл `train_v5.py`*, строки 61–65. Обучение слоя. Логистическая регрессия с балансом классов; для шумного варианта в обучение добавляются шумные окна, а в тест — всегда только окна отложенных записей.*

```
58  folds = list(GroupKFold(n_splits=5).split(XA, YA, GA))
```

Файл `train_v5.py`*, строки 58–58. Разбиение на 5 частей по записям (по номеру записи, а не по окну).*

```
78  def fuse(P, T=1.0, wv=None):
79      wv = WV if wv is None else wv
80      z = (np.log(np.clip(P, 1e-9, 1)) + wv[None, :] * raw) / T; z -= z.max(1, keepdims=True); p =
    ↳ np.exp(z); return p / p.sum(1, keepdims=True)
```

Файл `train_v5.py`*, строки 78–80. Смешивание слоя с баллами BirdNET и подбор температуры (калибровка).*

> **Простыми словами: честная проверка**
> Экзамен, на который можно прийти с подготовленными ответами, ничего не доказывает. Поэтому когда мы проверяем модель на записи, мы заранее прячем эту запись и все её кусочки от обучения. Если бы мы прятали только отдельные кусочки, остальные кусочки той же записи «подсказали» бы ответ, и точность вышла бы красивее, чем на самом деле.

5.5. Экспорт: что попадает в приложение

```
191      fin = LogisticRegression(C=CREG, max_iter=800, class_weight='balanced').fit(XA, YA)
192      fcls = [str(x) for x in fin.classes_]
193      common = [('' if x == 'background' else (labels.get(x) or xc.get(x) or x)) for x in fcls]
194      np.savez_compressed(APP + r'\models\head.npz', coef=fin.coef_.astype('float16'),
     ↳ intercept=fin.intercept_.astype('float32'), classes=np.array(fcls), common=np.array(common),
195                          T=np.float32(TB_), w=WV.astype('float32'), missing=np.float32(0.0),
     ↳ bn_labels=np.array([x if x in labels else '' for x in fcls]))
```

Файл `train_v5.py`, строки 191–195. Финальное обучение на всех записях и сохранение. Коэффициенты хранятся в 16-битном формате, поэтому файл весит около 500 КБ.

В файле `head.npz` лежат: коэффициенты, смещения, список классов (латинские и обычные названия), температура *T*, веса BirdNET по видам и таблица соответствия видов меткам BirdNET. Для браузера те же числа записываются в `head_web.json/bin`, а скрипт паритета проверяет, что ответы браузера и сервера совпадают на контрольных окнах. Список использованных записей публикуется в `head_training_sources.csv` (с номерами Xeno-canto и ссылками), чтобы каждый мог проверить, на чём учились.

6. Как мы проверяли качество и что получили

6.1. Протокол

- **Разбиение по записям**, 5 частей. Ни одна запись не бывает и в обучении, и в тесте.
- **Точность по окну**: доля 3-секундных окон, где первый ответ модели — верный вид. Окна без птицы тоже входят в тест (правильный ответ — «фон»).
- **Точность по записи**: ответы по всем окнам одной записи усредняются, побеждает вид с наибольшей средней вероятностью.
- **Сравнение с BirdNET** двух видов: «как есть» (учитывает все его 6 522 меток, как он публикуется) и «ограниченный» нашим списком видов (честнее для сравнения на шуме).
- **Отдельно на шуме**: те же окна с добавленным шумом разных типов и уровней.

6.2. Главный результат

Показатель	BirdNET	WetlandEar
Чистые окна, честное сравнение: BirdNET на нашем списке видов, без фильтра места	**61,1%**	**74,2%**
Шумные окна, то же честное сравнение	51,0%	**67,5%**
Запись целиком (голосование по окнам)	не измерялось	**85,0%**
Для справки: чистые окна, цифра, которую проект публиковал раньше (BirdNET «свободный», с фильтром места Кургальджина)	56,3%	74,2%

Находка при подготовке отчёта: прежняя базовая цифра BirdNET занижена
Раньше проект сравнивал себя с цифрой **56,3%** («BirdNET как есть»). Она посчитана так, что ответы BirdNET отсекались фильтром места, настроенным на одну точку (Кургальджино): виды, которые там маловероятны, BirdNET в этом подсчёте назвать **не мог по построению**. Но записи в тесте взяты со всего мира.
Проверка (скрипт `check_plaus.py`): **20 видов**, которые BirdNET знает (белый аист, серая неясыть, сойка, глухарь и др.), фильтр отключает полностью; у них точность BirdNET ровно 0%, они составляют 7,6% всех окон. Остальные виды, известные BirdNET, дают у него в среднем 63,6%.
Поэтому **честное сравнение** — BirdNET на нашем списке видов **без** фильтра места: 61,1% против 74,2% у нашего слоя, то есть отрыв **около 13,1 п.п.**, а не 17,9, как публиковалось. Отрыв по-прежнему значительный, но меньше. Сайт wetlandear.tech/metrics и таблицы v1–v5 в репозитории используют прежнюю цифру: их нужно пересчитать. Для v6 скрипт обучения уже считает честные базовые линии отдельно.

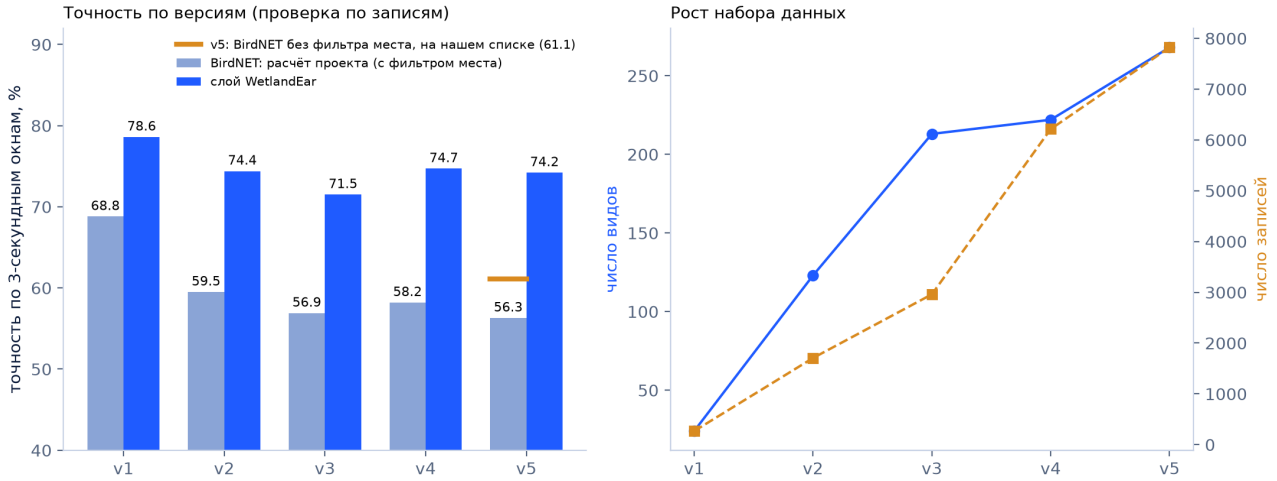


Рис. 5. Слева: точность по версиям. Голубые столбцы — прежний расчёт BirdNET (с фильтром места, он занижен); оранжевая черта у v5 — честное сравнение. С ростом числа видов абсолютная точность снижается (задача сложнее), но отрыв сохраняется. Справа: рост набора данных.

Абсолютная точность 74% по окнам не должна пугать: окно — всего 3 секунды, в нём птица может молчать, а виды бывают очень похожи по голосу. Для записи целиком (несколько окон) точность выше — 85%. Для сравнения: в версии v1 при 24 видах точность была 78,6%, но выбрать из 24 проще, чем из 268.

6.3. Шум

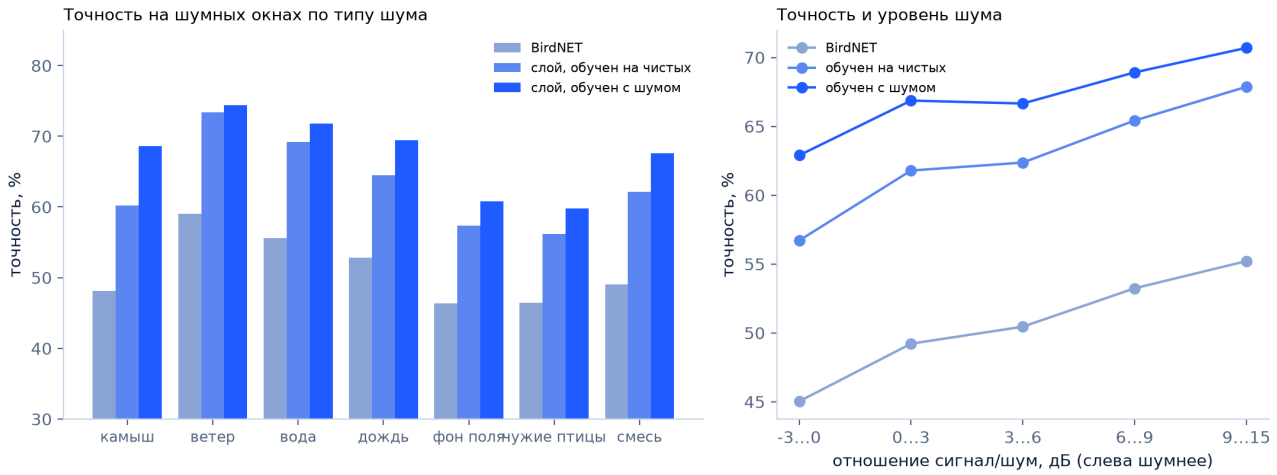


Рис. 6. Точность на окнах с шумом. Слева по типам шума, справа по уровню (слева шумнее). Слой, обученный с шумовыми копиями, лучше слоя, обученного на чистых данных, во всех случаях.

Хуже всего модель справляется, когда одновременно поют другие птицы и когда фоновый шум сильный: это самые тяжёлые случаи и для людей. Шум в тесте частично синтетический, поэтому настоящие полевые записи могут вести себя иначе; оценка на реальных записях заповедника — ближайшая задача (см. главу 11).

6.4. Можно ли верить процентам

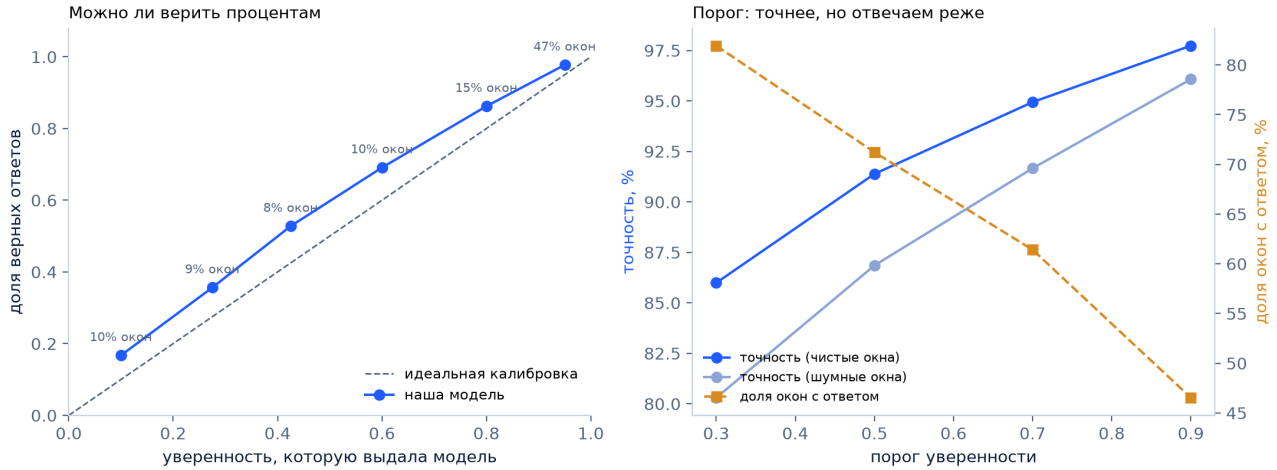


Рис. 7. Слева: если модель говорит «0,8», как часто она права. Идеальная модель идёт по диагонали. Справа: чем выше порог уверенности, тем выше точность, но тем реже модель отвечает.

Калибровка хорошая: чем выше заявленная уверенность, тем выше реальная доля верных ответов. При уверенности от 0,5 модель отвечает на 71,2% чистых окон и права в 91,4% случаев; от 0,7 — отвечает на 61,4% и права в 94,9%. В приложении ответ подставляется сам только от 0,5, остальное требует подтверждения человека. На шумных записях при том же пороге 0,5 модель отвечает реже (64,4% окон) и ошибается чаще (точность 86,9%).

6.5. По видам

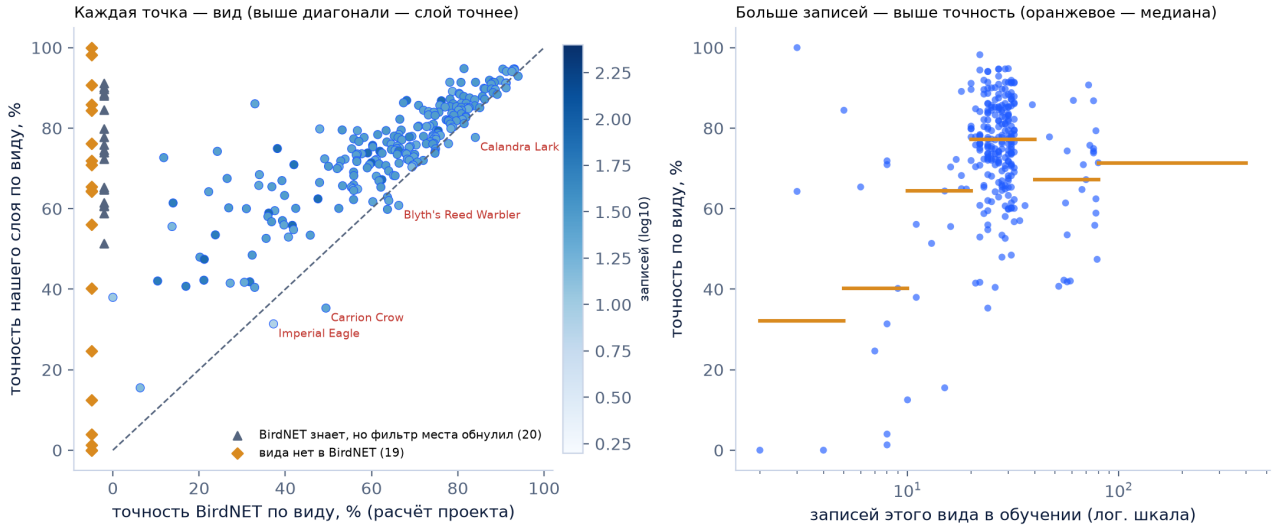


Рис. 8. Слева: каждая точка — вид. Выше диагонали модель точнее BirdNET. Оранжевые ромбы на левой оси — виды, которых в BirdNET нет. Подписаны виды, где мы хуже. Справа: точность растёт с числом записей вида.

Распределение видов по точности нашего слоя: 90% и выше: **24**, 70–90%: **162**, 50–70%: **61**, ниже 50%: **21**. Видов, которых BirdNET не знает вовсе, **19**: для них любой ответ нашего слоя — чистый выигрыш. Ещё **20** видов BirdNET знает, но фильтр места в прежнем подсчёте их обнулил (серые треугольники на рисунке), поэтому сравнивать по ним нельзя. Из остальных **229** видов, где сравнение корректно, наш слой точнее у **210**, равен у 6 и хуже у **13** (самые заметные — чёрная ворона, степной жаворонок, могильник, садовая камышевка). Здесь «по виду» сравнивается прежняя базовая цифра, поэтому на отрыв по отдельным видам тоже стоит смотреть осторожно: честную поэтапную таблицу даст пересчёт v6.

Самые слабые виды (v5)

Вид	Записей	Наш слой	BirdNET
Кудрявый пеликан	2	0,0%	нет в BirdNET
Бородатая куропатка	4	0,0%	нет в BirdNET
Розовый пеликан	8	1,3%	нет в BirdNET
Стервятник	8	4,0%	нет в BirdNET
Ланнер	10	12,5%	нет в BirdNET
Морская чернеть	15	15,5%	6,3%
Савка	7	24,6%	нет в BirdNET
Могильник	8	31,4%	37,3%
Чёрная ворона	24	35,3%	49,4%
Степной орёл	11	38,0%	0,0%
Чёрный жаворонок	9	40,2%	нет в BirdNET
Луток	26	40,4%	32,9%

* BirdNET знает этот вид, но в прежнем подсчёте его ответ отсекался фильтром места, поэтому 0% — не его настоящая точность.

У всех слабых видов, кроме отдельных случаев, мало записей. Это не «ошибка алгоритма», а нехватка данных. Для таких видов приложение показывает метку «мало примеров у модели», и к их ответам нужно относиться осторожнее.

Самые сильные виды (v5)

Вид	Записей	Наш слой	BirdNET
Джек	3	100,0%	нет в BirdNET
Черноголовый хохотун	22	98,2%	нет в BirdNET
Розовый скворец	30	94,8%	81,4%
Совка-сплюшка	29	94,7%	93,1%
Золотистая щурка	27	94,7%	92,9%
Щегол	27	94,7%	90,4%
Пеночка-трещотка	22	94,4%	93,1%
Дроздовидная камышевка	24	94,1%	91,3%

7. История, ветви развития и репозитории

7.1. Как шло развитие модели



Рис. 9. Основная линия (v1 → v5) и боковые ветви: идеи, которые проверили и отвергли. Серые рамки показывают результаты, а не домыслы.

Версия	Видов	Записей	BirdNET*	Наш слой	Что изменилось
v1	24	267	68,8%	78,6%	Первая проверка идеи: слой поверх BirdNET работает
v2	123	1 706	59,5%	74,4%	Сравнение моделей: линейный слой лучше MLP; добавка YAMNet не нужна
v3	213	2 960	56,9%	71,5%	Больше видов; калибровка уверенности; публикация таблицы по видам
v4	222	6 214	58,2%	74,7%	Больше записей; шумовые копии; измерение устойчивости к шуму
v5	268	7 822	56,3%	74,2%	Больше видов и записей; редкие виды — всё пригодное с Xeno-canto
v6	270	9 857	57,5%	70,5%	Выложена: +2 042 записи iNaturalist, очистка меток, честная базовая линия (глава 13)

* Это прежний расчёт проекта (с фильтром места); для v5 честное сравнение даёт 61,1% вместо 56,3%, см. 6.2. Для v1–v4 честная цифра не пересчитывалась.

7.2. Что мы пробовали и отвергли

- **Нейросеть MLP** вместо линейного слоя: 56,5% против 72,5% (v2). Нейросеть хуже на нашем объёме данных и дольше учится.
- **Отпечатки YAMNet** как добавка: 72,4% против 72,5%. Пользы нет, усложнение лишнее.
- **Баллы BirdNET как признаки** (stacking): лучше по записи целиком (83,3%), но не лучше по окну; выбрано смешивание.
- **Свой вес BirdNET для каждого вида**: на записях, которые не участвовали в подборе весов, не помогло (71,2% → 70,9%). Оставили один вес.

7.3. Репозитории и ветки Git

Работа ведётся в трёх репозиториях. Во всех используется **одна ветка — main**: проект делают двое, изменения небольшие и частые, а откат выполняется через историю коммитов. Если вы ожидали увидеть много параллельных веток, их действительно нет, и мы не будем притворяться, что есть. «Ветвями» в этом отчёте названы направления развития модели (рис. 9) и две линии обучения: на чистых данных и на данных с шумом.

Репозиторий	Что в нём	Коммитов	Доступ
wetlandear-app	Приложение, серверные функции, модель (head.npz), база (SQL), документация	60+	публичный код приложения (деплой с main)
wetlandear	Сайт проекта, страница метрик, политика конфиденциальности	10	публичный сайт
wetlandear-ml	Скрипты обучения, журналы и метрики v1–v5, этот отчёт	6+	закрытый

Простыми словами: ветка в Git
Ветка — параллельная копия проекта, где можно пробовать идею, не ломая основную версию. Когда идея сработала, её сливают обратно. Мы пробовали идеи (MLP, YAMNet) локально в скриптах-экспериментах, а в основную линию попадало только проверенное. Поэтому формально хватило одной ветки, а все «ветви» развития видны в таблице результатов выше.

8. Тревоги: выстрелы и двигатели

Помимо птиц система сообщает о выстрелах и шуме двигателей (бензопилы, лодки, машины), для заповедника это тревожные сигналы. За это отвечает YAMNet: он оценивает 521 тип звука, мы объединили родственные в группы (выстрел, двигатель, животное, погода, речь, собака). Правила тревоги: «выстрел» — оценка группы не ниже 0,35; «двигатель» — не ниже 0,3 при том, что оценка «животное» ниже 0,5.

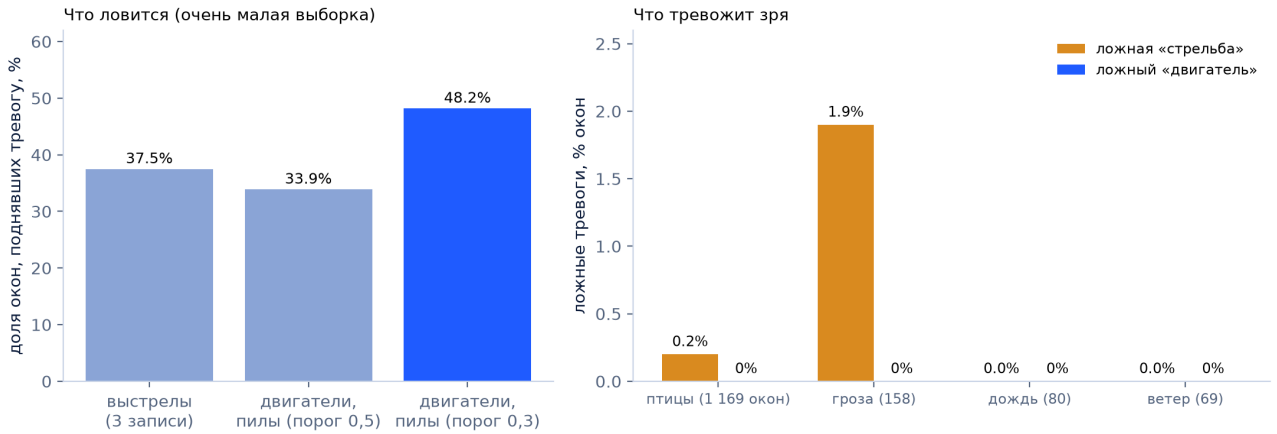


Рис. 10. Слева: доля окон, поднявших тревогу, на настоящих открытых записях. Справа: ложные тревоги на птицах и погоде. Выстрелов в проверке было только три пригодные записи.

Звук	Окон	Тревога «выстрел» (≥0,35)	Тревога «двигатель» (≥0,3)
Выстрелы (3 записи)	24	37,5% (2 из 3 записей распознаны)	0%
Бензопилы и двигатели	56	0%	48% (при пороге 0,5 было 34%)
Гроза	158	1,9%	0%
Дождь	80	0%	0%
Ветер	69	0%	0%
Птицы (Xeno-canto)	1 169	0,2%	0%

Что здесь доказано, а что нет
Хорошо измерено: ложные тревоги. На 1 169 окнах птиц, 80 окнах дождя и 69 окнах ветра ложных тревог по технике нет, по выстрелам 2 на птицах и 3 на грозе. **Плохо измерено:** способность поймать настоящий выстрел. Пригодных открытых записей оказалось всего три, значит это оценка «порядка величины», а не точная цифра. Порог для техники снижен с 0,5 до 0,3 именно по результатам этой проверки: ловим больше, ложных тревог по-прежнему нет. Нужны записи настоящих выстрелов из заповедника.

9. Приложение, база и безопасность

9.1. Что умеет приложение (вокруг модели)

- **Проверка событий** с несколькими вариантами и процентами: человек подтверждает, исправляет или пишет свой вариант.
- **Режим без интернета**: BirdNET и наш слой запускаются в браузере; ответы совпадают с серверными.
- **Научить голосу**: заповедник может добавить свой вид из нескольких записей; в браузере обучается маленький классификатор (логистическая регрессия, 300 шагов), а набор из 809 «чужих» отпечатков защищает от ложных срабатываний. Проверка: при 5 записях находит около 70% фрагментов этого вида при 0,2% ложных.
- **Фенология и индикаторные виды**: даты первых и последних встреч по годам, график «здоровья» болота по выбранным видам.
- **Защита мест гнёзд**: у редких видов координаты в выгрузках огрубляются до 0,1°, на публичных страницах эти виды скрыты.

- **Управление**: задачи рейнджерам, проверка экспертом по ссылке, публичные страницы с QR, отчёты для спонсоров, филиалы, недельная сводка директору.

9.2. База данных

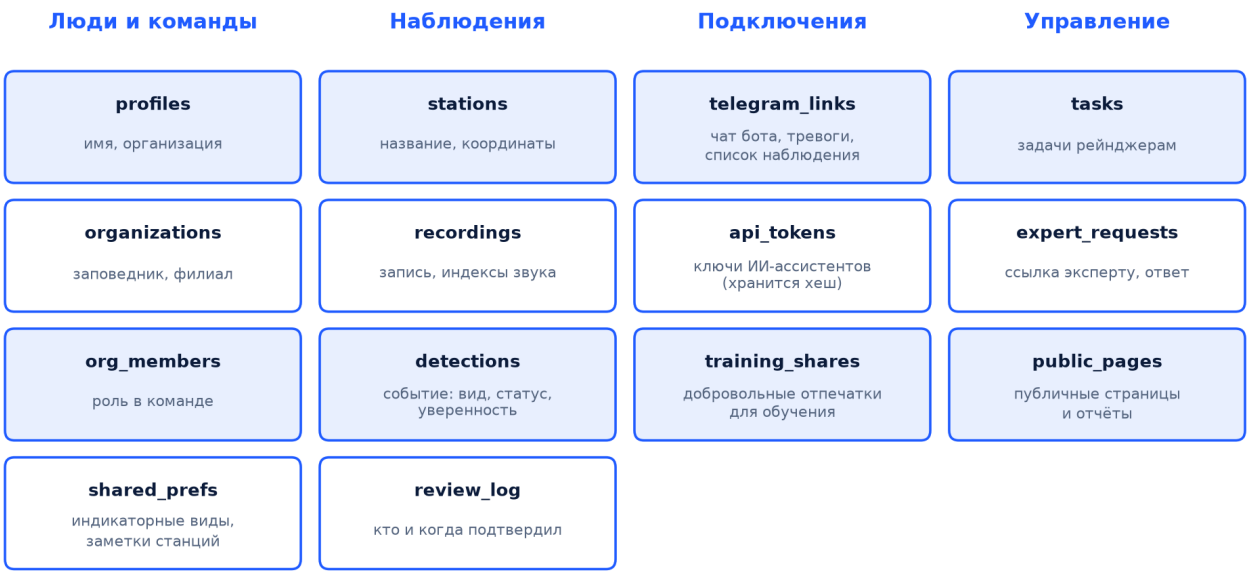


Рис. 11. Таблицы базы (Supabase/Postgres), сгруппированные по назначению. У каждой включены правила доступа на уровне строк.

Главный принцип: **каждый видит своё и данные своей команды, остальное закрыто на уровне базы**, а не только в интерфейсе. Например, человек из команды видит события коллег, но не может изменить чужие записи; ссылка эксперта читается только через сервер и даёт доступ к одной записи; публичная страница отдаёт сводку без координат и без видов из защищаемого списка. Роли в команде: владелец, редактор, наблюдатель. Каждое подтверждение пишется в журнал проверок (кто, когда, что изменил).

Аудиоклипы лежат в закрытом хранилище, по папке на человека. Секретные ключи сервера (Telegram, база, ИИ) есть только в переменных окружения Vercel. Приложение работает со строгой политикой безопасности браузера: без встроенных скриптов, с ограниченным списком внешних адресов.

10. Честные ограничения

Хороший отчёт не только хвалит, но и показывает, где результату нельзя верить без оговорок.

1. **Базовая линия BirdNET.** Публиковавшаяся цифра BirdNET (56,3%) занижена фильтром места (см. 6.2); честный отрыв около 13 п.п., а не 18. Метрики на сайте и в таблицах v1–v4 надо пересчитать.
2. **Тест на открытых записях, а не на вашем болоте.** Xeno-canto — это чаще чистые записи с микрофоном рядом с птицей. На реальном рекордере с ветром, водой и расстоянием точность будет ниже. Эту оценку ещё предстоит сделать.
3. **Шум частично синтетический.** Устойчивость к шуму измерена на «искусственно испорченных» окнах; настоящий шум может отличаться.
4. **Редкие виды: мало данных.** У кудрявого пеликана 2 записи, у ряда хищников 3–10. Точность по таким видам невысока и сильно колеблется.

5. **Метки в базах могут быть неверны.** Подписи делают люди; мы нашли 9 неверных из 33 проверенных вручную файлов, а проверить остальные 9 800 по имени файла нельзя.
6. **Лицензии.** BirdNET и многие записи Xeno-canto — «не для коммерции». Для платных услуг заповедникам нужна юридическая проверка или смена источников данных.
7. **Модель не учитывает сезон.** Мета-модель BirdNET работает по месту, но не по времени года; сезонная подсказка основана на частоте записей Xeno-canto и сама смещена: любители пишут больше весной.
8. **Одна птица на окно.** Первый ответ — один вид; несколько вариантов с процентами показываются, но два вида, поющие одновременно, различаются плохо.
9. **Тревоги.** Способность поймать выстрел проверена на трёх записях, поэтому хорошей оценки у нас нет.
10. **Не заменяет эксперта.** Модель предлагает; решение, особенно по редкому виду, остаётся за человеком.

11. Что дальше

- **v6 уже выложена** (глава 13): 2 042 открытых записей iNaturalist для 205 видов, 9 неверно подписанных файлов убраны, метка «мало примеров у модели» показывается в приложении.
- **Проверка на реальных записях заповедника.** Нужна выборка записей, размеченных орнитологом, чтобы честно измерить точность в полевых условиях и пересчитать пороги.
- **Данные от заповедников.** Функция «датасет заповедника» в приложении собирает размеченные звуки; после согласия владельцев и проверки лицензий они дополнят обучение именно для слабых видов.
- **Сезонность.** Учесть время года в списке правдоподобных видов.
- **Тревоги.** Собрать записи настоящих выстрелов и техники из заповедника и пересчитать пороги по надёжной выборке.
- **Автоматическая проверка меток.** Находить подозрительные подписи по расхождению отпечатка записи со средним по виду.

12. Как воспроизвести

Все пути в скриптах указывают на рабочую папку автора (в листингах она заменена на <папка проекта>); перед запуском поменяйте BASE в начале файла. Файлы BirdNET V2.4 берутся с официальной страницы BirdNET-Analyzer. Ключ Xeno-canto задаётся переменной окружения XC_KEY и нигде не хранится.

```
#!/bin/bash
cd <папка проекта>
PY=./venv/Scripts/python.exe
rm -rf feats3 feats_noisy
echo "[chain7] features (only changed species)"; $PY -I build_feats2.py 14 > chain7_feats2.log 2>&1
echo "[chain7] logits"; $PY -I build_logits.py > chain7_logits.log 2>&1
echo "[chain7] noisy"; $PY -I build_noisy.py 14 > chain7_noisy.log 2>&1
echo "[chain7] train + export"; $PY -I train_v5.py --export > chain7_train.log 2>&1
$PY -I make_species_js.py > chain7_js.log 2>&1
echo CHAIN7_DONE
```

Файл `final_chain7.sh`, строки 1–10. Цепочка полного пересчёта: признаки (только изменившиеся виды), баллы BirdNET, шумовые копии, обучение и экспорт.

Файл	Назначение
`train_v5.py`	Основной скрипт обучения, проверки и экспорта
`build_feats2.py, build_logits.py, build_noisy.py`	Подготовка признаков, баллов BirdNET и шумовых копий

Файл	Назначение
`fetch_xc*.py, fetch_inat.py`	Загрузка записей
`audit_labels.py`	Аудит подписей, карантин подозрительных файлов
`make_head_web.py, export_parity.py`	Версия для браузера, проверка совпадения с сервером
`eval_alerts.py`	Проверка тревог на открытых записях
`check_plaus.py`	Проверка: какие виды отсекает фильтр места в базовой линии BirdNET
`sim_voices*.py, test_worker.js`	Проверка режима «научить голосу»
`paper/make_figures.py, paper/build_paper.py`	Построение графиков и этого отчёта

13. Обновление: модель v6 выложена

Основная часть отчёта описывает v5. После неё мы обучили v6 и выложили её в приложение. Эта глава коротко рассказывает, что изменилось, как мы её проверяли и где мы сначала ошиблись в выводе.

13.1. Что изменилось

- К данным добавлены **2 042 открытые записи iNaturalist** для 205 видов (лицензии CC0, CC BY, CC BY-SA). Всего **270 видов и 9 857 записей** (в v5: 268 и 7 822).
- Убраны **9 неверно подписанных файлов** (глава 3.4), подписи ручного этапа теперь сверяются скриптом.
- Скрипт обучения теперь считает **честную базовую линию** отдельно (BirdNET на нашем списке видов без фильтра места) и разбивает результат по источникам записей.
- В приложении виды с малым числом записей помечаются «мало примеров у модели». Кэш модели для работы без интернета обновится у людей сам.

13.2. Один и тот же тест, два вида записей

Сначала мы сравнили v6 и v5 по общему числу и увидели падение: 70,5% вместо 74,2%. Это сбило нас с толку, потому что в тест попали и трудные записи iNaturalist (часто с телефонов, в полевых условиях). Правильное сравнение — на одном и том же тесте, отдельно для каждого источника: слой, обученный **без** iNaturalist (как v5), и слой, обученный **на всём** (как v6), проверялись на отложенных записях обоих источников.

Тестовые записи	BirdNET	Без iNaturalist (как v5)	На всём (v6)
Xeno-canto, чистые окна	61,1%	73,9%	73,6%
iNaturalist, чистые окна	41,4%	47,1%	**56,8%**
iNaturalist, окна с шумом	24,5%	30,5%	**37,9%**
Запись целиком, Xeno-canto	не измерялось	83,5%	83,2%
Запись целиком, iNaturalist	не измерялось	58,9%	**70,0%**

Вывод и поправка к первому выводу
Добавление записей iNaturalist **не ухудшило** работу на привычных записях Xeno-canto (73,6% против 73,9%, разница в пределах погрешности) и **заметно улучшило** работу на более трудных полевых записях: +9,7 п.п. по окнам и +11,1 п.п. по записи целиком. Поэтому v6 выложена.
Первый вывод («v6 хуже») был неверным: мы сравнили цифры на разных тестах. Мы остановили выкладку, провели правильное сравнение и исправили вывод.
Оговорка: записи одного наблюдателя на iNaturalist могут попадать и в обучающую, и в проверочную часть одного разбиения, поэтому прирост на iNaturalist мог получиться немного завышенным. На Xeno-canto эта проблема не влияет на вывод «ничего не потеряли».

13.3. Общие цифры v6

Показатель	v5	v6
Видов	268	270
Записей	7 822	9 857
Чистые окна: BirdNET (честное сравнение)	61,1%	57,5%
Чистые окна: наш слой	74,2%	70,5%
Отрыв, п.п.	13,1	13,0
Окна с шумом: BirdNET → наш слой	51,0% → 67,5%	45,9% → 61,5%
Запись целиком	85,0%	82,5%

Общие цифры v6 ниже, потому что тест теперь шире и содержит трудные записи; отрыв от честного BirdNET при этом остался прежним. По слабым видам картина смешанная: заметно выросли савка (с 25% до 54%), розовый пеликан (с 1% до 12%) и ланнер (с 12% до 29%), а у некоторых видов с 3–11 записями (джек, степной лунь) цифры просели. На таких выборках результат сильно колеблется. Кудрявый пеликан по-прежнему не распознаётся: у него 2 записи.

13.4. Сбой, который мы поймали

При обучении v6 на ноутбуке с малым объёмом свободной памяти расчёт баллов BirdNET несколько раз падал, а часть записей молча пропускалась. В результате в 6 папках видов файл баллов оказался короче файла признаков, и скрипт обучения пропускал такие папки целиком: первая версия v6 училась без этих видов и показала бы заниженные результаты. Мы нашли это по строке в журнале («264 вида вместо 268»), остановили обучение и добавили скрипт `check_align.py`: он отказывается начинать обучение, если хоть одна папка рассогласована. Боевая модель в этот момент не пострадала.

Приложение А. Глоссарий

Термин	Что значит
Спектрограмма	Картинка звука: по горизонтали время, по вертикали частота, яркость показывает громкость.
Окно	Кусочек звука длиной 3 секунды, с которым работает модель.
Отпечаток (эмбеддинг)	Набор из 1024 чисел, в который BirdNET превращает окно. Похожие звуки дают похожие наборы.
Слой, «голова» (head)	Наша маленькая модель, которая по отпечатку выбирает вид.
Логистическая регрессия	Простейший метод классификации: взвешенная сумма признаков для каждого класса, затем выбор большего.
Softmax	Способ превратить набор баллов в проценты, которые в сумме дают 100%.
Логит	Балл до превращения в вероятность. Чем больше, тем увереннее.
Температура	Число, на которое делят баллы перед softmax. Оно «успокаивает» или «усиливает» уверенность и нужно для калибровки.
Калибровка	Согласование заявленной уверенности с реальной долей верных ответов.
Переобучение	Когда модель запомнила обучающие примеры вместо закономерностей и плохо работает на новых.
Кросс-валидация	Проверка, когда данные несколько раз делят на обучение и тест и усредняют результаты.
SNR (сигнал/шум)	Во сколько раз полезный звук громче фона, в децибелах.
Фон (background)	Класс «птицы нет», в который попадают самые тихие окна записей.
Мета-модель	Часть BirdNET, оценивающая по координатам, какие виды вообще встречаются в точке.
Фильтр места	Отсечение видов, маловероятных в данной точке по мета-модели. В приложении полезен, в тесте с записями со всего мира искажает сравнение.
YAMNet	Нейросеть Google, различающая 521 тип звука (выстрел, двигатель, дождь, речь).
PWA	Веб-приложение, которое можно установить на телефон и использовать без интернета.
RLS	Правила доступа на уровне строк базы данных: каждый видит только положенное.
MCP	Протокол, позволяющий ИИ-ассистентам безопасно читать данные приложения от имени человека.
GBIF, eBird	Международные базы наблюдений, куда учёные выгружают данные о находках.
Xeno-canto, iNaturalist	Открытые базы записей и наблюдений природы, пополняемые учёными и любителями.

Приложение Б. Источники и благодарности

1. Kahl S., Wood C.M., Eibl M., Klinck H. BirdNET: A deep learning solution for avian diversity monitoring. *Ecological Informatics*, 61, 101236, 2021.
2. Gemmeke J.F. и др. Audio Set: An ontology and human-labeled dataset for audio events. *ICASSP*, 2017 (набор, на котором обучена YAMNet).
3. Guo C., Pleiss G., Sun Y., Weinberger K.Q. On Calibration of Modern Neural Networks. *ICML*, 2017 (температурная калибровка).
4. Alain G., Bengio Y. Understanding intermediate layers using linear classifier probes, 2016 (идея обучения линейного слоя поверх готовых признаков).
5. Pedregosa F. и др. Scikit-learn: Machine Learning in Python. *JMLR*, 12, 2011.
6. Xeno-canto Foundation. Xeno-canto: sharing bird sounds from around the world. https://xeno-canto.org
7. iNaturalist. https://www.inaturalist.org (записи использованы только под лицензиями CC0, CC BY, CC BY-SA).

Благодарности авторам записей Xeno-canto и iNaturalist: полный список использованных записей с номерами и ссылками лежит в файле `head_training_sources.csv` рядом с моделью. Модель и данные предназначены для некоммерческих исследований и образования.

Приложение В. Точность по каждому из 268 видов

Проверка по записям (5 частей). «Нет в BirdNET» означает, что такого вида нет в его списке меток. Шум — точность на тех же записях с добавленным шумом. Таблица отсортирована по точности нашего слоя. Звёздочка у BirdNET (0,0%*): вид BirdNET знает, но в прежнем подсчёте его ответ отсекал фильтр места, поэтому эта цифра не отражает его настоящую точность.

Вид	Латинское название	Записей	Окон	Наш слой	BirdNET	С шумом
Джек	*Chlamydotis macqueenii*	3	5	100,0%	–	60,0%
Черноголовый хохотун	*Larus ichthyaetus*	22	170	98,2%	–	92,6%
Розовый скворец	*Pastor roseus*	30	307	94,8%	81,4%	78,5%
Совка-сплюшка	*Otus scops*	29	321	94,7%	93,1%	84,4%
Золотистая щурка	*Merops apiaster*	27	282	94,7%	92,9%	80,9%
Щегол	*Carduelis carduelis*	27	356	94,7%	90,4%	88,6%
Пеночка-трещотка	*Phylloscopus sibilatrix*	22	305	94,4%	93,1%	94,3%
Дроздовидная камышевка	*Acrocephalus arundinaceus*	24	321	94,1%	91,3%	93,4%
Пёстрый сверчок	*Locustella naevia*	24	269	94,1%	92,6%	88,1%
Чёрный стриж	*Apus apus*	27	183	92,9%	94,0%	92,5%
Обыкновенный козодой	*Caprimulgus europaeus*	23	235	91,9%	89,8%	81,0%
Большой кроншнеп	*Numenius arquata*	31	308	91,9%	87,3%	83,9%
Рябинник	*Turdus pilaris*	29	338	91,4%	88,2%	83,9%
Желтоголовый королёк	*Regulus regulus*	24	279	91,4%	78,1%	90,8%
Белохвостая пигалица	*Vanellus leucurus*	32	302	91,4%	84,1%	84,2%

Вид	Латинское название	Записей	Окон	Наш слой	BirdNET	С шумом
Озёрная чайка	*Chroicocephalus ridibundus*	30	301	91,4%	80,7%	82,6%
Малый зуёк	*Charadrius dubius*	31	312	91,3%	88,5%	81,8%
Погоныш	*Porzana porzana*	32	353	91,2%	91,2%	91,8%
Речной сверчок	*Locustella fluviatilis*	31	364	91,2%	0,0%*	87,5%
Обыкновенная горлица	*Streptopelia turtur*	20	203	91,1%	91,1%	88,4%
Фифи	*Tringa glareola*	27	220	90,9%	87,7%	83,0%
Галка	*Coloeus monedula*	72	711	90,7%	–	90,1%
Белый аист	*Ciconia ciconia*	26	252	90,1%	0,0%*	87,0%
Коростель	*Crex crex*	25	250	90,0%	91,2%	87,6%
Воронок	*Delichon urbicum*	24	287	89,9%	86,1%	78,6%
Черныш	*Tringa ochropus*	29	234	89,7%	86,3%	88,0%
Обыкновенная овсянка	*Emberiza citrinella*	28	369	89,7%	87,8%	85,4%
Серая неясыть	*Strix aluco*	20	183	89,6%	0,0%*	78,7%
Сорока	*Pica pica*	23	230	89,6%	88,7%	89,5%
Персидская щурка	*Merops persicus*	18	193	89,1%	78,8%	72,4%
Перевозчик	*Actitis hypoleucos*	31	313	88,8%	88,2%	84,8%
Чиж	*Spinus spinus*	24	264	88,6%	80,3%	78,1%
Лесной жаворонок	*Lullula arborea*	23	312	88,5%	0,0%*	81,2%
Рогатый жаворонок	*Eremophila alpestris*	27	328	88,4%	80,5%	84,0%
Лебедь-кликун	*Cygnus cygnus*	30	396	88,4%	89,1%	76,7%
Пустынный жаворонок	*Ammomanes deserti*	29	219	88,1%	0,0%*	69,8%
Белолобый гусь	*Anser albifrons*	31	322	87,9%	85,7%	76,8%
Серый журавль	*Grus grus*	32	371	87,9%	81,4%	89,0%
Луговая тиркушка	*Glareola pratincola*	27	232	87,5%	82,8%	84,9%
Жулан	*Lanius collurio*	31	344	87,2%	78,2%	75,7%
Грач	*Corvus frugilegus*	31	327	87,2%	86,2%	82,9%
Береговая ласточка	*Riparia riparia*	26	193	87,0%	83,9%	74,8%
Журавль-красавка	*Anthropoides virgo*	61	587	86,9%	68,1%	80,0%
Луговой конёк	*Anthus pratensis*	76	697	86,8%	76,2%	78,7%
Сизая чайка	*Larus canus*	32	365	86,3%	67,4%	83,1%
Степная пустельга	*Falco naumanni*	24	224	86,2%	80,8%	77,9%
Чирок-свистунок	*Anas crecca*	29	238	86,1%	81,9%	77,3%
Орлан-белохвост	*Haliaeetus albicilla*	32	337	86,1%	78,9%	84,2%
Клёст-еловик	*Loxia curvirostra*	24	258	86,0%	32,9%	68,8%
Двупятнистый жаворонок	*Melanocorypha bimaculata*	39	430	85,8%	–	63,5%
Белощёкая крачка	*Chlidonias hybrida*	28	244	85,7%	70,9%	77,2%
Деревенская ласточка	*Hirundo rustica*	25	244	85,7%	75,8%	82,4%
Чибис	*Vanellus vanellus*	31	311	85,5%	83,9%	87,4%
Восточный соловей	*Luscinia luscinia*	30	395	85,3%	78,2%	78,1%

Вид	Латинское название	Записей	Окон	Наш слой	BirdNET	С шумом
Коноплянка	*Linaria cannabina*	27	320	85,3%	79,7%	78,7%
Полевой воробей	*Passer montanus*	26	305	85,2%	77,0%	74,7%
Жёлтая трясогузка	*Motacilla flava*	25	256	85,2%	82,0%	83,5%
Бекас	*Gallinago gallinago*	30	276	85,1%	80,8%	75,0%
Шилоклювка	*Recurvirostra avosetta*	29	342	85,1%	85,1%	79,3%
Лесной конёк	*Anthus trivialis*	27	328	85,1%	82,6%	80,7%
Теньковка	*Phylloscopus collybita*	21	250	84,8%	82,4%	81,5%
Серый сорокопут	*Lanius excubitor*	27	331	84,6%	0,0%*	76,1%
Ремез	*Remiz pendulinus*	28	251	84,5%	80,9%	83,0%
Лазоревка	*Cyanistes caeruleus*	25	315	84,4%	72,1%	83,1%
Орлан-долгохвост	*Haliaeetus leucoryphus*	5	45	84,4%	–	78,0%
Галстучник	*Charadrius hiaticula*	24	212	84,4%	80,2%	82,8%
Мухоловка-пеструшка	*Ficedula hypoleuca*	22	258	84,1%	73,3%	85,0%
Соловьиный сверчок	*Locustella luscinioides*	28	324	84,0%	75,6%	78,7%
Тростниковая камышевка	*Acrocephalus scirpaceus*	24	274	83,9%	74,5%	74,1%
Вальдшнеп	*Scolopax rusticola*	24	257	83,7%	78,6%	86,1%
Фазан	*Phasianus colchicus*	30	219	83,6%	80,8%	79,2%
Речная крачка	*Sterna hirundo*	26	287	83,3%	73,2%	81,8%
Камышовая овсянка	*Emberiza schoeniclus*	30	387	83,2%	79,1%	80,3%
Фламинго розовый	*Phoenicopterus roseus*	30	285	83,2%	74,7%	77,2%
Степной конёк	*Anthus campestris*	28	304	82,9%	81,9%	73,8%
Кольчатая горлица	*Streptopelia decaocto*	29	259	82,6%	81,9%	78,9%
Скопа	*Pandion haliaetus*	32	281	82,2%	66,5%	79,4%
Обыкновенный соловей	*Luscinia megarhynchos*	23	285	82,1%	81,1%	81,4%
Золотистая ржанка	*Pluvialis apricaria*	30	251	82,1%	77,3%	73,0%
Обыкновенный зимородок	*Alcedo atthis*	24	228	82,0%	78,1%	81,3%
Ворон	*Corvus corax*	27	314	81,8%	77,7%	80,1%
Зелёнушка	*Chloris chloris*	27	324	81,8%	79,6%	76,1%
Обыкновенная кукушка	*Cuculus canorus*	30	312	81,7%	77,9%	75,6%
Усатая синица	*Panurus biarmicus*	29	286	81,1%	81,5%	72,6%
Огарь	*Tadorna ferruginea*	29	300	81,0%	74,3%	82,0%
Средний кроншнеп	*Numenius phaeopus*	28	221	81,0%	78,3%	79,3%
Малый жаворонок	*Calandrella brachydactyla*	20	241	80,5%	73,4%	68,0%
Чеглок	*Falco subbuteo*	31	282	80,5%	70,9%	75,3%
Горихвостка-лысушка	*Phoenicurus phoenicurus*	23	301	80,4%	72,8%	77,6%
Водяной пастушок	*Rallus aquaticus*	27	239	80,3%	70,7%	67,4%
Лесная завирушка	*Prunella modularis*	24	288	80,2%	78,8%	80,6%
Чёрный дрозд	*Turdus merula*	20	199	79,9%	78,4%	70,2%
Орёл-карлик	*Hieraaetus pennatus*	20	198	79,8%	48,0%	68,4%

Вид	Латинское название	Записей	Окон	Наш слой	BirdNET	С шумом
Сойка	*Garrulus glandarius*	24	277	79,8%	0,0%*	79,8%
Кулик-воробей	*Calidris minuta*	32	220	79,5%	53,2%	77,4%
Ушастая сова	*Asio otus*	30	332	79,5%	66,9%	64,5%
Иволга	*Oriolus oriolus*	32	393	79,4%	63,4%	77,1%
Белохвостый песочник	*Calidris temminckii*	25	97	79,4%	56,7%	79,3%
Хохлатый жаворонок	*Galerida cristata*	29	276	79,3%	75,0%	81,3%
Щёголь	*Tringa erythropus*	78	644	79,3%	75,5%	75,4%
Лысуха	*Fulica atra*	31	272	78,7%	75,4%	77,8%
Авдотка	*Burhinus oedicnemus*	32	324	78,4%	61,4%	73,8%
Большая синица	*Parus major*	22	273	78,4%	66,3%	74,6%
Белая трясогузка	*Motacilla alba*	28	225	78,2%	74,2%	71,2%
Юрок	*Fringilla montifringilla*	22	266	78,2%	75,9%	70,9%
Большая поганка	*Podiceps cristatus*	31	282	78,0%	65,2%	65,1%
Певчий дрозд	*Turdus philomelos*	22	186	78,0%	69,4%	55,6%
Кряква	*Anas platyrhynchos*	30	254	78,0%	72,0%	68,4%
Тетеревятник	*Accipiter gentilis*	21	194	77,8%	74,2%	73,7%
Красноголовая овсянка	*Emberiza bruniceps*	47	595	77,8%	68,7%	68,9%
Домовый воробей	*Passer domesticus*	20	234	77,8%	74,8%	61,1%
Черноголовый чекан	*Saxicola rubicola*	27	319	77,7%	0,0%*	76,1%
Широконоска	*Spatula clypeata*	31	260	77,7%	66,2%	60,2%
Степной жаворонок	*Melanocorypha calandra*	24	251	77,7%	84,1%	49,2%
Белокрылая крачка	*Chlidonias leucopterus*	28	242	77,7%	58,3%	62,9%
Пискулька	*Anser erythropus*	30	247	77,3%	55,9%	72,1%
Ходулочник	*Himantopus himantopus*	25	242	77,3%	74,4%	75,9%
Горихвостка-чернушка	*Phoenicurus ochruros*	24	307	77,2%	74,9%	72,3%
Полевой жаворонок	*Alauda arvensis*	26	288	77,1%	67,0%	58,7%
Беркут	*Aquila chrysaetos*	31	326	76,7%	57,1%	59,8%
Чайконосая крачка	*Gelochelidon nilotica*	28	231	76,6%	73,6%	67,4%
Камышница	*Gallinula chloropus*	32	192	76,6%	63,5%	69,1%
Краснозобая казарка	*Branta ruficollis*	22	202	76,2%	–	73,9%
Пустынная каменка	*Oenanthe isabellina*	28	290	76,2%	74,5%	67,9%
Перепел	*Coturnix coturnix*	22	176	76,1%	77,8%	84,6%
Серая куропатка	*Perdix perdix*	30	205	76,1%	72,7%	67,3%
Вертишейка	*Jynx torquilla*	31	380	76,1%	74,2%	75,4%
Зарянка	*Erithacus rubecula*	22	175	76,0%	64,6%	57,5%
Обыкновенный глухарь	*Tetrao urogallus*	24	245	75,9%	0,0%*	52,8%
Черноголовая славка	*Sylvia atricapilla*	21	273	75,8%	70,3%	77,0%
Серая ворона	*Corvus cornix*	73	478	75,7%	60,3%	65,5%
Дербник	*Falco columbarius*	24	241	75,5%	66,0%	75,4%

Вид	Латинское название	Записей	Окон	Наш слой	BirdNET	С шумом
Зелёная пересмешка	*Hippolais icterina*	25	277	75,5%	69,0%	59,2%
Чёрный коршун	*Milvus migrans*	31	219	75,3%	60,3%	78,0%
Серая мухоловка	*Muscicapa striata*	24	246	75,2%	68,7%	65,4%
Пеночка-весничка	*Phylloscopus trochilus*	22	248	75,0%	66,5%	80,0%
Белоголовый сип	*Gyps fulvus*	76	726	74,9%	38,2%	58,6%
Болотная камышевка	*Acrocephalus palustris*	25	331	74,9%	65,9%	57,4%
Малая крачка	*Sternula albifrons*	26	195	74,9%	55,4%	71,2%
Сапсан	*Falco peregrinus*	28	298	74,8%	74,8%	69,4%
Малый лебедь	*Cygnus columbianus*	31	387	74,7%	64,6%	72,8%
Тетерев	*Lyrurus tetrix*	22	255	74,5%	65,5%	64,3%
Серебристая чайка	*Larus argentatus*	30	298	74,5%	0,0%*	67,7%
Стрепет	*Tetrax tetrax*	57	635	74,3%	66,3%	76,8%
Серощёкая поганка	*Podiceps grisegena*	76	835	74,3%	61,9%	73,2%
Кобчик	*Falco vespertinus*	27	260	74,2%	24,2%	69,2%
Камышевка-барсучок	*Acrocephalus schoenobaenus*	27	332	74,1%	74,7%	70,0%
Зелёный дятел	*Picus viridis*	32	235	74,0%	0,0%*	78,5%
Удод	*Upupa epops*	76	902	73,8%	59,1%	65,7%
Серый гусь	*Anser anser*	31	324	73,8%	74,7%	68,1%
Чернозобик	*Calidris alpina*	31	221	73,8%	62,4%	68,1%
Красношейная поганка	*Podiceps auritus*	24	274	73,7%	67,9%	59,6%
Красноголовый нырок	*Aythya ferina*	25	201	73,6%	57,7%	65,4%
Обыкновенный скворец	*Sturnus vulgaris*	26	284	73,6%	56,7%	60,5%
Обыкновенный дубонос	*Coccothraustes coccothraustes*	24	276	73,6%	68,1%	69,1%
Выпь	*Botaurus stellaris*	31	230	73,5%	70,0%	80,1%
Тулес	*Pluvialis squatarola*	30	279	73,5%	65,9%	70,2%
Малый веретенник	*Limosa lapponica*	27	225	73,3%	56,4%	72,4%
Обыкновенная чечевица	*Carpodacus erythrinus*	24	298	72,8%	69,8%	82,6%
Ястребиная славка	*Curruca nisoria*	29	322	72,7%	11,8%	72,0%
Белая куропатка	*Lagopus lagopus*	24	250	72,4%	0,0%*	81,0%
Белобрюхий рябок	*Pterocles alchata*	25	228	72,4%	49,1%	63,2%
Соловьиная камышевка	*Cettia cetti*	23	130	72,3%	53,8%	77,6%
Травник	*Tringa totanus*	26	249	72,3%	68,3%	71,9%
Саджа	*Syrrhaptes paradoxus*	17	144	72,2%	61,1%	72,8%
Обыкновенная каменка	*Oenanthe oenanthe*	25	243	72,0%	68,7%	60,8%
Испанский воробей	*Passer hispaniolensis*	24	268	72,0%	60,8%	67,5%
Большой веретенник	*Limosa limosa*	27	282	72,0%	72,0%	71,1%
Славка-завирушка	*Curruca curruca*	20	221	71,9%	56,6%	66,4%
Алтайский улар	*Tetraogallus altaicus*	8	96	71,9%	–	76,1%

Вид	Латинское название	Записей	Окон	Наш слой	BirdNET	С шумом
Лебедь-шипун	*Cygnus olor*	30	316	71,8%	52,8%	68,3%
Колпица	*Platalea leucorodia*	30	304	71,7%	56,6%	50,9%
Перепелятник	*Accipiter nisus*	27	211	71,6%	70,6%	62,1%
Болотный лунь	*Circus aeruginosus*	80	881	71,4%	59,9%	61,2%
Горная трясогузка	*Motacilla cinerea*	27	223	71,3%	66,4%	65,4%
Вяхирь	*Columba palumbus*	31	332	71,1%	61,7%	60,4%
Луговая тиркушка	*Glareola nordmanni*	8	86	70,9%	–	61,1%
Каменка-плясунья	*Oenanthe deserti*	68	674	70,9%	42,0%	63,7%
Круглоносый плавунчик	*Phalaropus lobatus*	26	237	70,9%	59,5%	73,3%
Малая поганка	*Tachybaptus ruficollis*	31	329	70,8%	69,6%	73,4%
Садовая овсянка	*Emberiza hortulana*	22	267	70,8%	69,7%	69,5%
Обыкновенный канюк	*Buteo buteo*	29	338	70,7%	63,3%	63,0%
Большая белая цапля	*Ardea alba*	31	190	70,5%	50,0%	66,9%
Малый азиатский жаворонок	*Alaudala cheleensis*	21	223	70,4%	52,5%	52,4%
Серая славка	*Curruca communis*	16	199	70,4%	69,3%	68,8%
Кеклик	*Alectoris chukar*	32	278	70,1%	59,0%	66,7%
Чёрная крачка	*Chlidonias niger*	29	223	70,0%	52,0%	61,2%
Кваква	*Nycticorax nycticorax*	28	222	69,4%	64,0%	67,0%
Мородунка	*Xenus cinereus*	32	317	69,1%	55,8%	71,6%
Чернозобый дрозд	*Turdus atrogularis*	24	206	68,4%	34,0%	55,5%
Зяблик	*Fringilla coelebs*	18	192	68,2%	65,1%	69,7%
Филин	*Bubo bubo*	31	374	68,2%	55,9%	60,5%
Жёлтоголовая трясогузка	*Motacilla citreola*	30	220	68,2%	65,5%	65,2%
Просянка	*Emberiza calandra*	25	288	68,1%	61,1%	74,6%
Монгольский зуёк	*Charadrius mongolus*	30	200	67,5%	26,5%	50,0%
Пеганка	*Tadorna tadorna*	70	622	67,2%	62,4%	58,6%
Поручейник	*Tringa stagnatilis*	30	227	67,0%	39,2%	67,0%
Хохлатая чернеть	*Aythya fuligula*	28	269	66,9%	61,7%	62,0%
Морской зуёк	*Charadrius alexandrinus*	27	194	66,5%	47,9%	71,5%
Обыкновенный гоголь	*Bucephala clangula*	28	317	65,9%	55,8%	63,7%
Каменный дрозд	*Monticola saxatilis*	23	260	65,8%	33,8%	66,5%
Домовый сыч	*Athene noctua*	29	306	65,7%	53,3%	59,8%
Сизоворонка	*Coracias garrulus*	28	301	65,4%	36,9%	53,5%
Кречётка	*Vanellus gregarius*	6	52	65,4%	–	50,0%
Чеграва	*Hydroprogne caspia*	31	251	65,3%	62,2%	60,6%
Тонкоклювая чайка	*Chroicocephalus genei*	23	199	65,3%	55,3%	59,3%
Рыжая цапля малая	*Ardeola ralloides*	30	167	65,3%	0,0%*	65,8%
Зимняк	*Buteo lagopus*	18	194	64,9%	55,7%	82,8%

Вид	Латинское название	Записей	Окон	Наш слой	BirdNET	С шумом
Сизый голубь	*Columba livia*	29	242	64,9%	0,0%*	61,6%
Большой пёстрый дятел	*Dendrocopos major*	19	185	64,9%	56,8%	66,7%
Черноголовая овсянка	*Emberiza melanocephala*	67	749	64,8%	0,0%*	59,2%
Большой улит	*Tringa nebularia*	28	265	64,5%	55,8%	57,7%
Курганник	*Buteo rufinus*	15	146	64,4%	–	56,6%
Балобан	*Falco cherrug*	3	28	64,3%	–	20,6%
Чёрный аист	*Ciconia nigra*	26	243	64,2%	22,2%	43,4%
Черношейная поганка	*Podiceps nigricollis*	30	226	63,3%	39,8%	58,7%
Серая утка	*Mareca strepera*	27	256	62,9%	63,7%	64,7%
Большой крохаль	*Mergus merganser*	78	740	62,4%	47,6%	52,7%
Красноносый нырок	*Netta rufina*	32	249	62,2%	55,8%	47,1%
Обыкновенная пустельга	*Falco tinnunculus*	24	200	62,0%	64,0%	62,4%
Свиязь	*Mareca penelope*	25	209	61,7%	60,3%	65,4%
Индийский гусь	*Anser indicus*	31	280	61,4%	0,0%*	48,4%
Индийская камышевка	*Acrocephalus agricola*	56	666	61,4%	14,0%	39,4%
Камышевка Блита	*Acrocephalus dumetorum*	22	273	60,8%	66,3%	51,6%
Таёжный гуменник	*Anser fabalis*	36	344	60,8%	0,0%*	50,8%
Египетская цапля	*Bubulcus ibis*	29	300	60,7%	0,0%*	56,2%
Краснозобик	*Calidris ferruginea*	31	201	60,2%	26,9%	47,0%
Клуша	*Larus fuscus*	31	283	60,1%	42,4%	54,2%
Тонкоклювая пересмешка	*Iduna caligata*	32	313	60,1%	52,4%	52,6%
Полевой лунь	*Circus cyaneus*	30	310	60,0%	31,0%	52,9%
Серая цапля	*Ardea cinerea*	30	234	59,8%	63,7%	63,9%
Змееяд	*Circaetus gallicus*	24	237	59,5%	37,6%	59,9%
Волчок	*Ixobrychus minutus*	78	523	58,9%	36,1%	49,8%
Рябчик	*Tetrastes bonasia*	23	262	58,8%	0,0%*	64,2%
Малая чайка	*Hydrocoloeus minutus*	29	267	58,1%	36,0%	42,7%
Луговой лунь	*Circus pygargus*	34	356	57,0%	39,3%	41,9%
Сибирский чекан	*Saxicola maurus*	32	326	56,7%	36,8%	57,4%
Дрофа	*Otis tarda*	11	123	56,1%	–	40,8%
Варакушка	*Luscinia svecica*	24	252	56,0%	39,7%	49,3%
Чирок-трескунок	*Spatula querquedula*	77	632	55,9%	41,6%	47,5%
Белая сова	*Bubo scandiacus*	16	153	55,6%	13,7%	32,6%
Болотная сова	*Asio flammeus*	24	241	54,8%	41,9%	61,7%
Хохотунья	*Larus cachinnans*	57	488	53,5%	23,8%	48,1%
Шилохвость	*Anas acuta*	28	249	53,4%	45,8%	49,3%
Большой подорлик	*Clanga clanga*	22	221	52,9%	40,7%	56,5%
Каменка-плешанка	*Oenanthe pleschanka*	29	287	52,6%	35,5%	41,1%
Тонкоклювый жаворонок	*Calandrella acutirostris*	13	146	51,4%	0,0%*	30,4%

Вид	Латинское название	Записей	Окон	Наш слой	BirdNET	С шумом
Длинноносый крохаль	*Mergus serrator*	31	260	48,5%	32,3%	43,0%
Чернолобый сорокопут	*Lanius minor*	28	317	47,9%	20,2%	42,8%
Каравайка	*Plegadis falcinellus*	79	599	47,4%	21,2%	38,1%
Рыжая цапля	*Ardea purpurea*	55	521	42,2%	21,1%	31,0%
Толстоклювый зуёк	*Charadrius leschenaultii*	59	395	42,0%	10,4%	28,9%
Малая белая цапля	*Egretta garzetta*	57	318	41,8%	31,8%	46,2%
Степной лунь	*Circus macrourus*	22	223	41,7%	30,5%	37,9%
Белоглазый нырок	*Aythya nyroca*	21	147	41,5%	27,2%	44,6%
Турухтан	*Calidris pugnax*	52	366	40,7%	16,9%	24,3%
Луток	*Mergellus albellus*	26	225	40,4%	32,9%	28,8%
Чёрный жаворонок	*Melanocorypha yeltoniensis*	9	107	40,2%	–	32,4%
Степной орёл	*Aquila nipalensis*	11	108	38,0%	0,0%	24,2%
Чёрная ворона	*Corvus corone*	24	170	35,3%	49,4%	33,3%
Могильник	*Aquila heliaca*	8	51	31,4%	37,3%	27,4%
Савка	*Oxyura leucocephala*	7	69	24,6%	–	38,9%
Морская чернеть	*Aythya marila*	15	142	15,5%	6,3%	12,2%
Ланнер	*Falco biarmicus*	10	96	12,5%	–	10,6%
Стервятник	*Neophron percnopterus*	8	75	4,0%	–	3,8%
Розовый пеликан	*Pelecanus onocrotalus*	8	76	1,3%	–	5,7%
Кудрявый пеликан	*Pelecanus crispus*	2	28	0,0%	–	0,0%
Бородатая куропатка	*Perdix dauurica*	4	37	0,0%	–	0,0%